Автоматическая генерация и отбор признаков для рекомендательной модели на основе градиентного бустинга

Эксперименты на данных Yambda-50M

Якубовская Анастасия Алексеевна

Математико-механический факультет СПбГУ,
программа «Искусственный интеллект и наука о данных»

Октябрь 2026

Аннотация

Качество индустриальных рекомендательных моделей во многом определяется признаками, которые инженеры придумывают вручную: агрегатами истории взаимодействий в фиксированных временных окнах. Мы исследуем, можно ли автоматизировать их построение, и сравниваем автоматические подходы с сильным ручным бейзлайном на градиентном бустинге при строгом временном протоколе (Yambda-50M: 1500 пользователей, 7,1 млн прослушиваний; ранжирование внутри групп «пользователь–день»; метрика NDCG@10 с доверительными интервалами по пользователям). Все решения принимались на валидации, а отложенный тест был использован один раз для каждой постановки.

Основные результаты. (i) Скользящие окна создают протокольный артефакт, снимок на начало суток его устраняет. (ii) Оптимальный масштаб окна зависит от агрегата. (iii) Автоматический отбор из широкого пула превосходит ручной набор при том же числе признаков; на тесте пул из 97 признаков лучше сильного ручного набора M2 на $+0{,}0028$ NDCG@10 [+0,0017; +0,0038], RFE-48 на $+0{,}0019$ [+0,0007; +0,0030], а для 26 признаков различие с M2 не доказано ($+0{,}0013$ [-0,0001; +0,0025]). (iv) Агенты, предлагающие признаки на ограниченном языке (3 поставщика $\times$ 10 запусков), статистически неразличимы; поиск ~ 4000 программ-признаков с калибровкой по перемешанным («нулевым») кандидатам не находит измеримого прироста над пулом: агрегаты истории насыщены. (v) Информация другой природы помогает: коллаборативные признаки со снимками по неделям дают $+0{,}0015$ [+0,0007; +0,0024] NDCG@10 на тесте и $+0{,}0179$ [+0,0154; +0,0202] среди новых для пользователя кандидатов, причём эффект растёт с размером графа. (vi) В расширенной постановке с непрослушанными кандидатами преимущество автоматического пула над ручным набором более чем вдвое больше ($+0{,}0265$ на тесте) и растёт с объёмом обучающих данных, тогда как ручной набор насыщается уже при ~ 400 пользователях. Последовательная модель над историей в нашей реализации бустингу не конкурирует.

Ключевые слова: автоматическая генерация признаков, градиентный бустинг, рекомендательные системы, утечки данных, коллаборативная фильтрация, кривые обучения.

Содержание

1 Введение **4**
1.1 Основные результаты . . . 4
1.2 Ход работы . . . 4
1.3 Структура отчёта . . . 5

2 Связанные работы **5**

3 Постановка задачи и обозначения **5**
3.1 Данные, метки, признаки по прошлому . . . 5
3.2 Ранжирование и метрики . . . 6
3.3 Расширенная постановка: непрослушанные кандидаты . . . 6
3.4 Задача отбора и язык программ-признаков . . . 7
3.5 Калибровка порога по нулевому распределению . . . 7

4 Данные и протокол **7**
4.1 Данные . . . 7
4.2 Протокол без утечек . . . 8
4.3 Статистика . . . 8

5 Методы **9**
5.1 Семейства признаков и наборы . . . 9
5.2 Модель и бейзлайны . . . 9
5.3 Методы отбора признаков . . . 10
5.4 Агент и язык признаков . . . 10
5.5 Графовые признаки (SVD-векторы вкуса) . . . 10
5.6 Последовательная модель (v1) . . . 10
5.7 Коллаборативные признаки со снимками по неделям . . . 10
5.8 Поиск программ-признаков с калибровкой (расширенная постановка) . . . 11

6 Результаты: основная постановка (валидация) **11**
6.1 Протокольный артефакт: скользящее окно и снимок . . . 12
6.2 Временные масштабы . . . 12
6.3 Вклад групп признаков и пулы . . . 13
6.4 Сравнение при равном числе признаков (sel/rep) . . . 13
6.5 Шум между запусками . . . 14
6.6 Настройка гиперпараметров . . . 14
6.7 Агент и язык признаков . . . 15
6.8 Пул v3: признаки агентов поверх пула . . . 16
6.9 Графовые признаки . . . 16
6.10 Страты и устойчивость по времени . . . 16
6.11 Избыточность и устойчивость отбора . . . 17
6.12 Бюджет истории . . . 17
6.13 Масштабируемость генератора признаков . . . 18
6.14 Последовательная модель над историей (v1) . . . 19

7 Результаты: расширенная постановка с непрослушанными кандидатами 19
7.1 Сравнение наборов: rep и тест . . . 20
7.2 Кривая обучения: сколько пользователей нужно . . . 20
7.3 Автоматический поиск программ-признаков с нулевой калибровкой . . . 21
7.4 Коллаборативные признаки . . . 23

8 Финальная оценка на тестовой выборке 25

9 Вычислительные затраты 26

10 Обсуждение 27
10.1 Ответ на вопрос задания . . . 27
10.2 Почему агрегаты насыщены, а постановка важна . . . 28
10.3 Масштаб данных . . . 28
10.4 Статистическая осторожность . . . 28

11 Ограничения 28

12 Заключение и перспективы 29
12.1 Заключение . . . 29
12.2 Перспективы и невыполненные эксперименты . . . 29

13 Воспроизводимость 30

Использование ИИ-инструментов 30

A Дополнительные таблицы 32
A.1 Качество одной фичи по окнам . . . 32
A.2 Страты и недели: полные таблицы (rep) . . . 32

1. Введение

Рекомендательные системы определяют, что ежедневно видят миллионы пользователей. Типичный промышленный конвейер ранжирования состоит из градиентного бустинга над таблицей признаков: признаков пользователя, объекта и пары «пользователь–объект». Последние (например, сколько раз пользователь слушал этот трек за последние w дней) обычно оказываются самыми информативными. Выбор w, набора агрегатов и типов связей делается вручную, поэтому возникает гипотеза, что этот выбор субоптимален: выбирая «7 дней», мы не знаем, не лучше ли «10» или «45».

Задача. Предложить процедуру построения признаков, не ограниченную решениями человека, и экспериментально сравнить её с хорошо настроенным бустингом на ручных признаках при одинаковых данных, разбиении, кандидатах и доступной информации. Условие допускает три направления: автоматическую генерацию и отбор признаков, графовые модели и модели над историей событий. Мы рассматриваем все три, основной упор делается на первое.

1.1. Основные результаты

1. Протокол важнее модели: при скользящих окнах удаление пользовательских признаков *повышает* метрику, при снимке на начало суток — нет (раздел 6.1).
2. Оптимальное окно зависит от агрегата: доля дослушиваний растёт до 180 дней, у счётчика максимум около 45 дней (разд. 6.2).
3. Автоматический отбор $\geq$ ручного выбора при равном числе признаков. **Тест:** пул v2 $-$ M2 $= +0{,}0028$ [+0,0017; +0,0038]; RFE-48 $-$ M2 $= +0{,}0019$ [+0,0007; +0,0030]; RFE-26 $-$ M2 $= +0{,}0013$ [-0,0001; +0,0025] (не доказано).
4. Агенты и поиск программ-признаков не превосходят отбор из пула; нулевая калибровка показала, что «победители» — шум (разд. 6.7, 7.3).
5. Коллаборативные признаки (сигнал других пользователей) дают небольшой общий и заметный выигрыш на новых для пользователя парах; выигрыш растёт с размером графа (разд. 7.4).
6. Разрыв «автоматика против ручного набора» растёт с объёмом данных, ручной набор насыщается рано (разд. 7.2).
7. Последовательная модель v1 (0,7112) заметно уступает бустингу (0,7792) и не улучшает его в стекинге (разд. 6.14).

1.2. Ход работы

Работа шла в шесть этапов; каждый следующий этап был ответом на вывод предыдущего.

1. **Бейзлайн и протокол.** Сборка конвейера без утечек, обнаружение протокольного артефакта скользящих окон (разд. 6.1).
2. **Масштабы окон и отбор.** Исследование окон, расширение пула, сравнение методов отбора на равном числе признаков (разд. 6.2–6.5).
3. **Агенты, граф, последовательная модель.** Три направления из условия: язык признаков для агента, SVD-векторы вкуса, трансформер над историей (разд. 6.7–6.14).
4. **Диагностика.** Страты, устойчивость по времени и отбору, избыточность, бюджет истории, масштабируемость (разд. 6.10–6.13).
5. **Расширенная постановка с негативными кандидатами** и два ночных эксперимента: поиск программ-признаков с калибровкой по нулям, коллаборативные признаки и кривая обучения (разд. 7).
6. **Финальный тест**: один запуск для каждой постановки с замороженными наборами (разд. 8).

1.3. Структура отчёта

Разделы 2–5 — связанные работы, постановка, данные и методы. Результаты основной постановки на валидации даны в разд. 6, расширенной постановки в разд. 7, финальный тест в разд. 8, затраты в разд. 9. Обсуждение, ограничения и воспроизводимость — разд. 10–13.

2. Связанные работы

Идея автоматического синтеза признаков восходит к Deep Feature Synthesis [1]: признаки строятся композицией простых примитивов по связям реляционных данных. Наша грамматика (ключ $\times$ агрегат $\times$ окно) — частный случай такой схемы для одной таблицы событий. В OpenFE [2] полезность кандидата оценивается «бустингом признаков»: на остатках базовой модели обучается модель с одним кандидатом, отсев идёт от грубого к точному. Наш поиск программ (разд. 7.3) использует тот же приём, но добавляет калибровку порога по перемешанным кандидатам. Для генерации признаков большими языковыми моделями предложены CAAFE [3] (итеративная генерация кода признаков с проверкой качества) и LLM-FE [4] (поиск программ с эволюционной оптимизацией, где LLM предлагает кандидатов, а качество на данных служит обратной связью). LLM-поставщик в нашем коде реализован, но не оценивался; сравниваются случайный, эволюционный и суррогатный поставщики.

Альтернативой ручным агрегатам служит обучение на реляционных данных как на временном графе [5] и генеративные модели над историей событий [6]; последовательные модели для рекомендаций [7] используют трансформерные энкодеры [8]. Мы используем графовую информацию как источник признаков бустинга и оцениваем небольшой трансформер (разд. 6.14). Коллаборативная фильтрация по соседям [9] и факторизация [10] — основа наших CF-признаков; низкоранговое разложение считается случайным SVD [11].

Выбор бустинга обоснован превосходством деревьев на табличных данных среднего размера [12]; необходимость строгого временного протокола — работой об утечках при офлайн-оценке [13]. Данные — Yambda [14]; модель — LightGBM [15] с целью LambdaRank/LambdaMART [16]; метрика — NDCG [17]. Доверительные интервалы строятся кластерным bootstrap по пользователям [19]. Калибровка порога по нулевому распределению близка по духу к эмпирическому нулю [20] и контролю доли ложных открытий [21]. Кривые обучения аппроксимируются степенным законом, как в [22].

3. Постановка задачи и обозначения

3.1. Данные, метки, признаки по прошлому

Дан набор событий $D = \{e_k = (u_k, i_k, t_k, r_k)\}$: пользователь u, трек i, время t (секунды), доля прослушивания $r \in [0, \infty)$ в процентах (значения > 100 возможны при перемотке). Метка прослушивания $y_e = \mathbb{1}[r_e \geq 50]$ (по карточке датасета трек считается прослушанным при проигрывании более 50%; мы используем нестрогое неравенство). Вспомогательные цели: $\tilde{r}_e = \min(r_e, 100)/100$, метка скипа $s_e = \mathbb{1}[\tilde{r}_e < 0{,}1]$, метка почти полного прослушивания $f_e = \mathbb{1}[\tilde{r}_e \geq 0{,}9]$.

Пусть $\Delta = 86400$ с, $\tau(t) = \lfloor t/\Delta \rfloor \Delta$ (начало суток).

Определение 1 (окно истории)**.** *Для ключа κ (функция, сопоставляющая событию группу: пользователь, трек, пара «пользователь–трек», «пользователь–исполнитель» и т. д.), окна w (в днях) и события $x = (u, i, t)$ положим*

$$E_{\kappa,w}(x) = \{e \in D : \ \kappa(e) = \kappa(x), \ \tau(t) - w\Delta \leq t_e < \tau(t)\}.$$

Агрегаты для цели $z \in \{y, \tilde{r}, s, f\}$:

$$\mathrm{cnt}_{\kappa,w}(x) = |E_{\kappa,w}(x)|, \qquad \mathrm{mean}^{z}_{\kappa,w}(x) = \frac{1}{|E_{\kappa,w}(x)|} \sum_{e \in E_{\kappa,w}(x)} z_e \quad (|E_{\kappa,w}(x)| > 0),$$

иначе значение пропущено. Давность: $\rho_\kappa(x) = \big(\tau(t) - \max\{t_e : \kappa(e) = \kappa(x),\, t_e < \tau(t)\}\big)/\Delta$. Для $z = y$ среднее называем долей (`rate`). Пространство кандидатов $\Phi = \{\varphi_{\kappa,\alpha,w}\}$, α пробегает агрегаты, конечно: $|\Phi| = |K||A||W|$.

Предложение 1 (отсутствие утечки)**.** *Значение любого признака $\varphi \in \Phi$ на событии x зависит от D только через события e с $t_e < \tau(t_x) \le t_x$. В частности, оно не зависит ни от y_x, ни от меток событий того же дня или позже.*

Доказательство. Каждое множество $E_{\kappa,w}(x)$ и величина $\rho_\kappa(x)$ определены через события с $t_e < \tau(t_x)$; агрегаты суть функции этих множеств. □

Предложение 2 (вычисление через префиксные суммы)**.** *Пусть события отсортированы по паре $(\kappa(e), t_e)$ и $S^z[j]$ — префиксные суммы цели z. Тогда для каждого x множество $E_{\kappa,w}(x)$ занимает непрерывный отрезок $[\mathrm{lo}, \mathrm{hi})$ этого порядка, границы находятся бинарным поиском, а $\sum_{e\in E_{\kappa,w}(x)} z_e = S^z[\mathrm{hi}] - S^z[\mathrm{lo}]$. Все окна одного ключа вычисляются за $O(n \log n)$ времени и $O(n)$ памяти.*

Доказательство. Условие $\kappa(e) = \kappa(x)$, $t_e \in [\tau(t_x) - w\Delta, \tau(t_x))$ задаёт полуинтервал в лексикографическом порядке (κ, t), то есть непрерывный отрезок. Концы находятся двумя бинарными поисками по $(\kappa(x), \tau(t_x))$ и $(\kappa(x), \tau(t_x) - w\Delta)$ с левой границей (это исключает события с совпадающим временем и само событие). Сумма на отрезке — разность префиксных сумм; сортировка стоит $O(n \log n)$, поиски — $O(\log n)$ на событие и окно. □

Предложение 2 показывает, что состояние на ключ можно накапливать потоково (достаточные статистики фиксированного размера), что важно для вопроса о масштабе.

3.2. Ранжирование и метрики

Группа $g(x) = (u, \lfloor t/\Delta \rfloor)$. Для группы с n_g объектами и $m_g = \sum_{x\in g} y_x$ положительными при ранжировании π по убыванию оценки:

$$\mathrm{DCG@}k(g) = \sum_{j=1}^{\min(k,n_g)} \frac{y_{\pi(j)}}{\log_2(j+1)}, \quad \mathrm{IDCG@}k(g) = \sum_{j=1}^{\min(k,m_g)} \frac{1}{\log_2(j+1)}, \quad \mathrm{NDCG@}k = \frac{1}{|G|}\sum_{g\in G} \frac{\mathrm{DCG@}k(g)}{\mathrm{IDCG@}k(g)},$$

где G — множество групп с $n_g \ge 10$ и $m_g \ge 1$; всюду $k = 10$. Дополнительно используются $\mathrm{Recall@}10 = \#\{\text{позитивы в топ-10}\}/m_g$, а также метрики, различающие *тип позитива*: позитив называется *новым*, если пользователь не слушал этот трек за всю предшествующую историю (`ui_cnt_400d`$= 0$), иначе *повторным*. $\mathrm{Recall}_{\text{нов}}$ и $\mathrm{Recall}_{\text{повт}}$ — доли найденных в топ-10 позитивов каждого типа. $\mathrm{NDCG}_{\text{нов}}@10$ — NDCG, посчитанный только по кандидатам, новым для пользователя (группы, где есть хотя бы один новый позитив); он отвечает на вопрос, насколько модель отличает понравившиеся новые треки от непонравившихся новых, и не зависит от конкуренции за места в топе с повторными треками.

3.3. Расширенная постановка: непрослушанные кандидаты

В основной постановке кандидаты — только прослушанные за день треки, поэтому метрика измеряет ранжирование *внутри* прослушанного (смещение отбора). В расширенной постановке к каждой группе (u, d) добавляется $n_{\text{neg}} = 20$ *негативов*: треков, которых пользователь не слушал в день d. Половина выбирается равномерно из каталога, половина пропорционально популярности; каталог и популярность берутся по событиям строго до начала соответствующей выборки (без будущего); треки, прослушанные пользователем в этот день, исключаются. Признаки негативов считаются тем же снимком на начало суток, что и для позитивов. Это не показы (данных о показах нет), а суррогат: «непрослушан» не означает «не понравится».

3.4. Задача отбора и язык программ-признаков

Модель f_θ обучается на обучающем периоде по признакам $S \subset \Phi$: $V(S) = \text{NDCG@10}_{\text{sel}}(f_{\hat{\theta}(S)})$, $S^* \in \arg\max_{|S| \le K} V(S)$. Это комбинаторная задача; методы автоматизации — её приближённые решения. В разд. 7.3 пространство расширяется до *выражений* $\text{op}(a, b)$, где a, b — базовые признаки или вложенные выражения, $\text{op} \in \{+, -, \times, \div\}$.

Предложение 3 (замкнутость относительно построчных операций)**.** *Пусть $\varphi_1, \dots, \varphi_m$ — признаки, значения которых на x зависят от D только через события с $t_e < \tau(t_x)$. Тогда любая функция $h(\varphi_1(x), \dots, \varphi_m(x))$ обладает тем же свойством. В частности, любое выражение языка программ над признаками из Φ не содержит утечки из будущего.*

Доказательство. $h(\varphi_1(x), \dots, \varphi_m(x))$ есть функция от x и значений $\varphi_j(x)$; последние зависят от D только через события до $\tau(t_x)$, а h не обращается к D. □

3.5. Калибровка порога по нулевому распределению

Пусть $G_1, \dots, G_K$ — приросты качества для K «нулевых» кандидатов (признаки, значения которых перемешаны между строками, то есть по построению не несут сигнала), и порог $\theta = G_{(m)}$, $m = \lceil qK \rceil$ — m-я порядковая статистика.

Предложение 4 (ложные принятия)**.** *Если нулевой прирост G_0 нового кандидата обменяем с $G_1, \dots, G_K$ и имеет непрерывное распределение, то* $\Pr(G_0 > \theta) = \dfrac{K - m + 1}{K + 1}$. *При $K = 300$, $q = 0{,}99$ это* $4/301 \approx 0{,}013$.

Доказательство. Ранг R величины G_0 среди $K+1$ обменяемых величин равномерен на $\{1, \dots, K+1\}$ (1 — наименьшая). Неравенство $G_0 > G_{(m)}$, где $G_{(m)}$ — m-я по величине среди остальных K, выполняется тогда и только тогда, когда $R \ge m + 1$; таких исходов $K + 1 - m$ из $K + 1$. □

Предложение носит оценочный характер: перемешанный кандидат — суррогат истинно нулевого признака (он сохраняет маргинальное распределение, но не его зависимость от базовых признаков). Ожидаемое число ложных принятий среди M реально бесполезных кандидатов оценивается как $M \cdot \Pr(G_0 > \theta)$; эта величина сравнивается с числом принятых кандидатов.

4. Данные и протокол

4.1. Данные

Использован датасет Yambda-50M [14]: по карточке датасета 10 000 пользователей, 934 057 треков и 46 467 212 прослушиваний (файл `flat/50m/multi_event.parquet`). Из него случайно (seed 42) выбрано 1500 пользователей со всеми их прослушиваниями (выборка по пользователям сохраняет целостность историй). Единицы времени проверены по данным: медиана отношения разрыва между соседними прослушиваниями к длительности прослушанной части равна 0,938, то есть `timestamp` — секунды; период около 301 дня.

Таблица 1: Параметры данных и протокола основной постановки

Подвыборка	1500 пользователей (seed 42), 7 110 081 прослушиваний, доля $y = 1$: 0,639
Разбиение по времени	80/10/10 по квантилям времени: train 5 688 063, val 711 007, test 711 011 строк
Периоды	train ≈253,6 дня, val ≈24,6 дня, test ≈22,7 дня
Окно обучения	последние 60 дней train; история для признаков берётся вся
Val: половины по пользователям	*sel* (решения, ранняя остановка): 8039 групп; *rep* (отчёт): 8213 групп; пересечение пользователей пусто (seed 123)
Тест	использован один раз для каждой постановки (разд. 8)

Таблица 2: Расширенная постановка: размеры выборок (кандидаты: прослушанные + 20 негативов на группу)

Выборка	Строк	в т. ч. негативов	Групп
train (60 дней)	2 308 447	705 360	35 268
sel	511 057	160 780	8 039
rep	524 990	164 260	8 213
test	1 029 031	318 020	15 901

4.2. Протокол без утечек

- Разбиение по глобальной временной оси (train $<$ val $<$ test) [13].
- Признаки считаются по определению из разд. 3 (предложение 1); корректность реализации проверена сравнением с наивным перебором на случайных строках для всех режимов и функций признаков.
- Признак `is_organic` исключён: это свойство самого прослушивания, при выдаче кандидатов неизвестное.
- Val разделён пополам по пользователям (seed 123): *sel* — все решения (ранняя остановка, отбор признаков, выбор между вариантами), *rep* — сравнения для отчёта.
- **Тест.** Наборы признаков фиксируются в файлах (`finalists_FROZEN.json`) до запуска; гиперпараметры — по умолчанию (правило разд. 6.6); оценка на тесте вычисляется один раз, повторный запуск блокируется файлом `TEST_LOCK.json`; результаты теста не использовались ни в каких решениях.

4.3. Статистика

Доверительные интервалы для разности метрик двух моделей строятся кластерным bootstrap по пользователям [19]: для групп g с $d_g = \mathrm{NDCG}_g^B - \mathrm{NDCG}_g^A$ обозначим $S_u = \sum_{g \in G_u} d_g$, $C_u = |G_u|$. На итерации $b = 1, \ldots, 1000$ пользователи выбираются с возвращением (множество U_b^*) и $\Delta_b^* = \sum_{u \in U_b^*} S_u / \sum_{u \in U_b^*} C_u$; 95%-й интервал — 2,5 и 97,5 перцентили $\{\Delta_b^*\}$. Интервал отражает вариативность по пользователям, но не учитывает отбор признаков по sel; случайность обучения оценивается отдельно по seed. Интервалы, пересекающие ноль, трактуются как «различие не доказано», а не «различия нет».

5. Методы

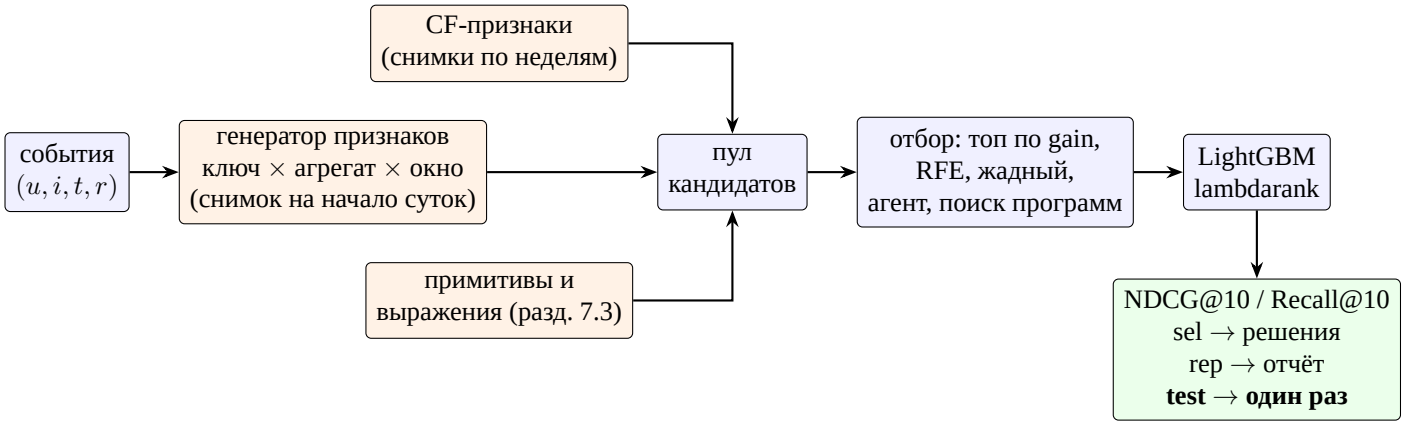


Рис. 1: Схема экспериментального конвейера (обе постановки).

5.1. Семейства признаков и наборы

Ключи: пользователь (`user`), трек (`item`, статистика внутри подвыборки), пара «пользователь–трек» (`ui`), «пользователь–исполнитель» (`uart`), «пользователь–альбом» (`ualb`), исполнитель и альбом (`art`, `alb`), а также статистика трека по всем 10 000 пользователям (`gitem`, только по прошлому). Агрегаты: число, доля дослушиваний, средняя доля прослушивания (`mean_pr`), доля скипов (`skip_rate`), доля почти полных прослушиваний (`full_rate`), давность. Сетка окон пула v1 (в днях; 400 — вся доступная история):

$$\{1, 2, 3, 5, 7, 10, 14, 21, 30, 45, 60, 90, 120, 180, 400\}.$$

Таблица 3: Наборы признаков основной постановки

Набор	Размер	Состав
M1 (ручной)	26	`user`, `item`, `ui` (cnt, rate; окна 1/7/30 дней), `gitem` (cnt, rate; окна 1/7/30/90)
M2 (сильный ручной)	48	все семейства пула v2 с «круглыми» окнами 1/7/30/90 дней и давностью, без отбора
Пул v1	74	`item`/`gitem` из M1 и `user`, `ui` на сетке из 15 окон
Пул v2	97	пул v1 + `ui_mean_pr` (7/30/90/400), давность пары, `uart` и `ualb` (cnt, rate; окна 7/30/90/400) и давность
Пул v3	123 / 169	пул v2 + признаки, принятые агентами (26 в первом запуске, 72 в итоговом)

В расширенной постановке: **manual18** — `user`, `ui`, `item` × окна 1/7/30 × (cnt, rate) = 18 признаков; **pool90** — 7 ключей × окна 1/7/30/90/400 (для `user`, `ui`, `uart`, `ualb`: cnt, rate, mean_pr; для `item`, `art`, `alb`: cnt, rate) = 90 признаков.

5.2. Модель и бейзлайны

LightGBM [15], цель `lambdarank` [16], оптимизация NDCG@10 внутри групп. Параметры по умолчанию: скорость 0,05, 63 листа, `min_data_in_leaf`$= 200$, `feature_fraction`$= 0{,}8$, `bagging_fraction`$= 0{,}8$, 63 корзины, не более 300 итераций, ранняя остановка по sel (30 итераций). Бейзлайны: M1 (стандартный) и M2 (сильный), оба затюнены по Optuna [18] (разд. 6.6).

5.3. Методы отбора признаков

A1 (по важности): обучить модель на пуле, оставить K признаков с наибольшим суммарным gain. **RFE (рекурсивное исключение):** пока $|S| > K$: обучить модель на S (остановка по sel), оставить $\max(K, \lfloor 0{,}85|S| \rfloor)$ признаков с наибольшим gain. **Greedy (жадный прямой отбор):** на быстрой модели-прокси (20% пользователей train, 60 деревьев, скорость 0,15, 31 лист) на каждом шаге из 10 кандидатов с наибольшим gain проверяется добавление каждого, выбирается признак с наибольшим приростом NDCG@10 на sel.

5.4. Агент и язык признаков

Агент не пишет код, а возвращает описание признака в строго ограниченной грамматике:

$$\text{feature} ::= \text{AGG}(\text{key}, \text{window}), \qquad \text{key} ::= \text{user} \mid \text{item} \mid \text{ui} \mid \text{uart} \mid \text{ualb} \mid \text{art} \mid \text{alb},$$
$$\text{AGG} ::= \text{cnt} \mid \text{rate} \mid \text{mean_pr} \mid \text{skip_rate} \mid \text{full_rate} \mid \text{recency}, \qquad \text{window} \in \{1, \ldots, 400\}.$$

Каждая программа компилируется в проверенную функцию, реализующую определения разд. 3, поэтому утечка исключена по построению (предложение 1). Цикл: база — M1 (26 признаков); за раунд оцениваются 8 программ по приросту NDCG@10 на sel быстрой модели-прокси; лучший принимается, если прирост выше порога $\theta = \max(0{,}0005, 2\sigma)$, где σ — стандартное отклонение прокси-метрики по трём seed ($\theta \approx 0{,}0015$). Бюджет: 10 раундов $\times$ 8 = 80 оценок. Поставщики: *random* (равномерный ключ и агрегат, окно логарифмически-равномерно); *evo* (с вероятностью 0,6 мутация программы с положительным приростом, иначе случайная); *surrogate* (после 16 случайных оценок случайный лес «программа $\to$ прирост», выбор 8 из 300 кандидатов по «среднее + std»). Поставщик на основе LLM реализован, но не оценивался.

5.5. Графовые признаки (SVD-векторы вкуса)

Матрица $M \in \{0,1\}^{U \times I}$ «пользователь дослушал трек» по событиям строго до начала окна обучения по всем 10 000 пользователям (16 578 011 дослушиваний, треки со степенью ≥ 5). Нормированная матрица $\tilde{M} = D_U^{-1/2} M D_I^{-1/2}$ раскладывается усечённым SVD ранга 16; вектор трека — строка $V\Sigma$ (126 175 треков). «Вектор вкуса» $c_w^+(x)$ — среднее векторов дослушанных треков из $E_{u,w}(x)$, «вектор неприязни» $c_w^-(x)$ — скипнутых; признаки: $\cos(v_i, c_w^+)$, $\cos(v_i, c_w^-)$ и их разность, $w \in \{30, 90, 400\}$ (9 признаков). Граф статичен и строится до всех строк обучения и оценки, поэтому утечки нет; платой является устаревание вложений.

5.6. Последовательная модель (v1)

Контекст — последние 64 события пользователя до начала суток; токен: SVD-вектор трека (16), флаг наличия вектора, метка y, доля прослушивания, логарифм давности (20 чисел). Небольшой трансформерный энкодер ($d_{\text{model}} = 64$) кодирует контекст; кандидат (SVD-вектор) подаётся запросом во внимание к контексту, на выходе — оценка. Потери — бинарная кросс-энтропия, 5 эпох. Оценки для обучающих строк получены кросс-подгонкой по двум половинам пользователей (для строки оценка получена моделью, не видевшей её пользователя); на sel и rep — среднее двух моделей. Оценка подаётся в бустинг как ещё один признак (стекинг).

5.7. Коллаборативные признаки со снимками по неделям

Для строки (u, i, d) берётся снимок S — начало недели, содержащей день d ($S \leq \tau(t)$), и матрица M_S «пользователь дослушал трек» по событиям *всех* 9238 пользователей с дослушиваниями строго до S. Строки матрицы взвешиваются по трекам весом $1/\sqrt{\ln(2 + \deg_i)}$ и нормируются (косинусная

близость s_{uv}). Для u берутся $K_1 = 50$ и $K_2 = 200$ ближайших соседей $N_K(u)$ (сам пользователь исключён). Признаки:

$$\text{cf_u}K(u,i) = \frac{\sum_{v \in N_K(u)} s_{uv} M_{vi}}{\sum_{v \in N_K(u)} s_{uv}}, \qquad \text{cf_u50cnt} = \sum_{v \in N_{50}(u)} M_{vi}, \qquad \text{cf_deg} = \ln(1 + \deg_i),$$

а также `cf_mf_dot`$= (U_u\Sigma) \cdot V_i$ и `cf_mf_cos` — оценки случайного SVD ранга 64 нормированной матрицы [11, 10]. Всего 6 признаков. Для треков без истории в снимке и пользователей без истории значения пропущены.

Предложение 5 (отсутствие утечки в CF-признаках)**.** *Значение каждого CF-признака на строке (u, i, t) зависит от D только через события с $t_e < S \le \tau(t)$.*

Доказательство. Матрица M_S построена по событиям с $t_e < S$; соседи, веса, SVD и все признаки — функции M_S и пары (u, i). Снимок для строки выбирается как начало недели, не позже $\tau(t)$. □

Платой за недельные снимки является устаревание до 7 дней. Реализация проверена на синтетических данных сравнением с наивным вычислением и тестом возмущения (перестановка меток событий после S не меняет признаки).

5.8. Поиск программ-признаков с калибровкой (расширенная постановка)

Примитивы. Помимо оконных агрегатов добавлено 35 признаков по полной истории ключа (до начала суток): давность последнего события, возраст (время от первого события), средний и последний интервалы между событиями, накопленное число событий (по 5 признаков для каждого из 7 ключей).

Язык выражений. $\text{op}(a, b)$, $\text{op} \in \{\text{diff}, \text{sum}, \text{mul}, \text{div}, \text{ratio}_1\}$ ($\text{ratio}_1(a, b) = a/(b + 1)$), глубина ≤ 2; утечки нет по предложению 3. Структурные кандидаты: *trend* (короткое окно против длинного), *hier* (пара против общего уровня: `ui` против `uart`, `user` и т. д.), *timing* (давность относительно привычного интервала), *burst* (доля прослушиваний окна в накопленном). Всего 400 структурных, 2468 «слепых» (случайные пары из 40 важнейших базовых признаков), 1058 кандидатов глубины 2.

Оценка кандидата. Базовая модель на всех базовых признаках и примитивах даёт out-of-fold оценку s_0 (две половины пользователей). Для кандидата c обучается маленькая модель только на c с `init_score`$= s_0$ (30 деревьев, 15 листьев, 30% групп — стадия 1; 100 деревьев на всех данных — стадия 2); «ценность» — прирост NDCG@10 на sel над s_0.

Нулевая калибровка. Те же процедуры запускаются на 300 (стадия 1) и 60 (стадия 2) «нулевых» кандидатах — реальных программах с перемешанными по строкам значениями. Порог принятия — 99-й процентиль нулевых приростов (предложение 4). Прошедшие порог стадии 2 диверсифицируются (отбрасываются признаки с $|\rho_{\text{Спирмен}}| > 0{,}9$ с уже принятым) и добавляются к базе по 5/10/20/40; число выбирается по sel.

6. Результаты: основная постановка (валидация)

Если не оговорено иное, метрика — NDCG@10; «val» — вся валидационная выборка, «sel/rep» — её половины. Показатели случайного порядка: val 0,6816, rep 0,6950, sel 0,6674; ранжирование по популярности трека (`gitem_rate_30d`): val 0,7064, rep 0,7226.

6.1. Протокольный артефакт: скользящее окно и снимок

В первой версии эксперимента признаки считались по точному моменту t (скользящее окно), модель обучалась с бинарной целью, ранжирование оценивалось в группах «пользователь–день». Удаление пользовательских признаков *повышало* NDCG@10 ($0{,}7343 \rightarrow 0{,}7509$) при падении AUC ($0{,}8283 \rightarrow 0{,}7158$). Причина: внутри группы пользовательская доля дослушиваний меняется от строки к строке, и модель использует «серии скипов» пользователя — закономерность реальную, но недоступную при выдаче рекомендаций, когда все кандидаты оцениваются в один момент. После перехода на снимок на начало суток и цель `lambdarank` эффект исчезает (рис. 2). Поскольку в этом сравнении одновременно меняются режим окна и цель, вывод относится к протоколу в целом.

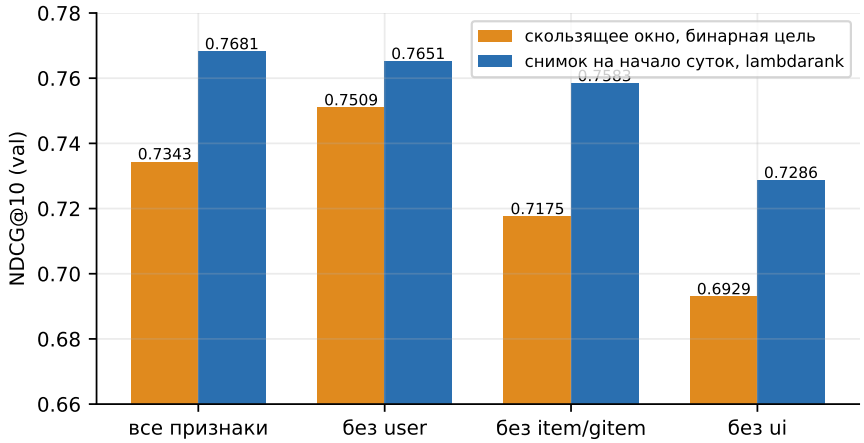


Рис. 2: Абляция групп признаков при двух протоколах (val). При скользящем окне удаление пользовательских признаков повышает NDCG@10; при снимке на начало суток — нет.

6.2. Временные масштабы

Рисунок 3 показывает качество ранжирования по одной фиче `ui_rate` или `ui_cnt` при разных окнах. Доля дослушиваний растёт монотонно до 180 дней ($0{,}7039 \rightarrow 0{,}7396$; значения при 180 и 400 днях совпадают, так как история ограничена), а у счётчика максимум приходится на 45 дней ($0{,}7294$), далее качество падает. Разница между окном 7 и 45 дней для счётчика составляет $+0{,}0102$, а для доли между 7 и 180 днями $+0{,}0197$: выбор окна «7 дней» заметно субоптимален. Гипотеза (не проверялась): среднее при увеличении окна лишь снижает шум, тогда как счётчик накапливает давние события.

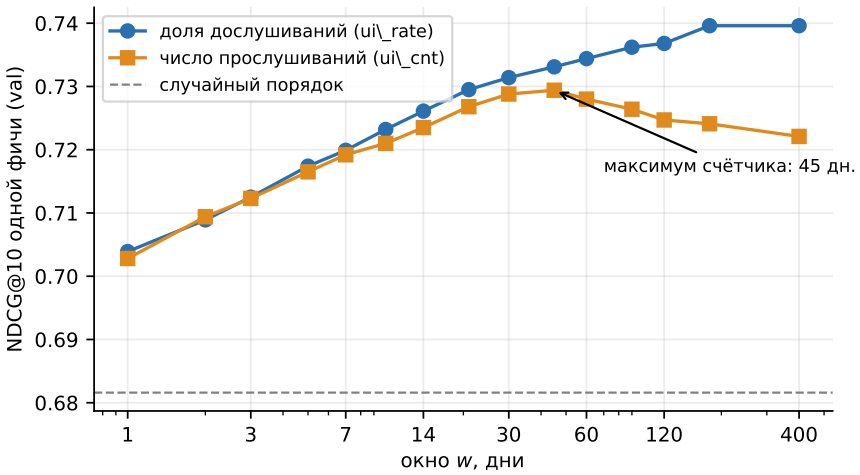


Рис. 3: NDCG@10 одной фичи (пара «пользователь–трек») в зависимости от окна (val). Полные значения — в приложении A.1.

6.3. Вклад групп признаков и пулы

Для M1 (26 признаков) NDCG@10 на val равен 0,7681. Абляция (удаление группы, среднее по 2 seed): без `user` 0,7651, без `item/gitem` 0,7583, без `ui` 0,7286; только `ui` — 0,7563. Решающим оказывается семейство пары «пользователь–трек» (около 55% суммарного gain; одна фича `ui_rate_30d` — 32%).

Таблица 4: Наборы признаков на валидации (параметры по умолчанию, один запуск); ДИ — кластерный bootstrap по пользователям

Набор	Признаков	NDCG@10	Разность (95% ДИ)
M1	26	0,7681	—
Пул v1	74	0,7779	$+0{,}0098$ к M1 [+0,0077; +0,0119]
Топ-30 из пула v1 (A1)	30	0,7764	$+0{,}0083$ к M1 [+0,0064; +0,0105]
M2	48	0,7772	$+0{,}0091$ к M1 [+0,0071; +0,0112]
Пул v2	97	0,7806	$+0{,}0125$ к M1 [+0,0102; +0,0148]; $+0{,}0034$ к M2 [+0,0021; +0,0047]
Топ-30 из пула v2 (A1)	30	0,7768	$-0{,}0004$ к M2 [-0,0018; +0,0011]

Из $+0{,}0125$ (пул v2 против M1) около $0{,}0098$ дают длинные окна, около $0{,}0027$ — новые семейства. Абляция семейств v2 (потеря при удалении): `ui_mean_pr` $-0{,}0018$ [-0,0029; -0,0007], `uart/ualb` $-0{,}0016$ [-0,0028; -0,0004], давность $-0{,}0005$ [-0,0014; +0,0005] (не отличима от нуля). По важности лидируют `ui_rate` (25%), `ui_mean_pr` (18%), `user_rate` (16%), `ui_cnt` (11%); важность не равна вкладу из-за коррелированности признаков.

6.4. Сравнение при равном числе признаков (sel/rep)

Оптимизм результатов предыдущего раздела связан с тем, что отбор и ранняя остановка шли по тому же val. Ниже все решения принимаются по sel, а сравнения — на rep (таблица 5). Приросты A1 на rep ($+0{,}0069$ и $+0{,}0021$–$0{,}0025$) меньше, чем на всём val ($+0{,}0086$ и $+0{,}0030$): часть прежнего преимущества была оптимизмом отбора. Преимущество пула v2 над M2 ($+0{,}0030$) не изменилось, поскольку в нём нет шага отбора.

Таблица 5: Сравнение на rep (параметры по умолчанию, один запуск). A1, RFE и Greedy отбирают по sel

K	Метод	sel	rep	Разность на rep (95% ДИ)
26	M1 (ручной)	0,7555	0,7792	—
26	A1	0,7664	0,7861	$+0{,}0069$ к M1 [+0,0039; +0,0098]
26	RFE	0,7678	0,7875	$+0{,}0084$ к M1 [+0,0055; +0,0111]; $+0{,}0015$ к A1 [+0,0001; +0,0028]
26	Greedy	0,7692	0,7866	$+0{,}0074$ к M1 [+0,0045; +0,0102]; $+0{,}0005$ к A1 [-0,0013; +0,0021]
48	M2 (сильный ручной)	0,7672	0,7864	$+0{,}0073$ к M1 [+0,0047; +0,0097]
48	A1	0,7703	0,7885	$+0{,}0025$ к M2 [+0,0005; +0,0043]
48	RFE	0,7698	0,7888	$+0{,}0028$ к M2 [+0,0010; +0,0046]; $+0{,}0003$ к A1 [-0,0011; +0,0016]
48	Greedy	0,7686	0,7880	$+0{,}0020$ к M2 [+0,0002; +0,0037]; $-0{,}0006$ к A1 [-0,0020; +0,0008]
97	Пул v2	0,7703	0,7894	$+0{,}0030$ к M2 [+0,0014; +0,0048]

Стоимость: A1 — одно обучение на пуле; RFE ($97 \to 48 \to 26$) — 9 обучений, 424 с; жадный отбор (48 шагов) — 26,7 мин. RFE не уступает жадному отбору по качеству, будучи в 3–4 раза дешевле. Кривая жадного отбора выходит на плато при $K \approx 15$–19: после этого колебания прокси-метрики ($\pm 0{,}001$) соответствуют шуму. Первые выбранные признаки: `ui_rate_400d`, `ui_cnt_90d`, `gitem_rate_90d`, `ui_mean_pr_90d`, `user_rate_60d`, `uart_rate_400d`.

6.5. Шум между запусками

Для оценки случайности обучения каждый финальный набор обучен с пятью seed (параметры по умолчанию).

Таблица 6: NDCG@10 (среднее $\pm$ стандартное отклонение по 5 seed), валидация

Набор	Признаков	sel	rep
M1	26	$0{,}7563 \pm 0{,}0008$	$0{,}7801 \pm 0{,}0006$
M2	48	$0{,}7669 \pm 0{,}0005$	$0{,}7864 \pm 0{,}0003$
RFE-26	26	$0{,}7687 \pm 0{,}0006$	$0{,}7880 \pm 0{,}0003$
RFE-48	48	$0{,}7699 \pm 0{,}0003$	$0{,}7889 \pm 0{,}0004$
Пул v2	97	$0{,}7705 \pm 0{,}0005$	$0{,}7897 \pm 0{,}0004$

Шум ($0{,}0003$–$0{,}0006$) существенно меньше разрыва между M1 и остальными наборами. На rep 26 автоматически отобранных признаков (RFE-26) лучше 48 ручных (M2) на $0{,}0016$: каждый из пяти запусков RFE-26 выше каждого из пяти запусков M2. Различие пула v2 и RFE-48 ($0{,}0008$) близко к удвоенному шуму. *Важно:* на отложенном тесте (разд. 8) аналогичная разность RFE-26 $-$ M2 равна $+0{,}0013$ [-0,0001; +0,0025], то есть различие в ту же сторону, но по пользователям не доказано.

6.6. Настройка гиперпараметров

Для M1, M2, RFE-26 и RFE-48 проведён поиск по Optuna [18] (TPE, 20 попыток на набор, критерий — NDCG@10 на sel, первой попыткой заданы значения по умолчанию). Пространство: скорость обучения $[0{,}03; 0{,}2]$, число листьев $[15; 255]$, `min_data_in_leaf`$\in [50; 1000]$, `feature_fraction` и `bagging_fraction` $[0{,}5; 1]$, $\lambda_2 \in [10^{-3}; 10]$.

Таблица 7: Параметры по умолчанию и после поиска (rep: среднее по seed; для defaults 5 seed, для tuned 3 seed)

Набор	лучший sel за поиск	rep, defaults	rep, tuned
M1	0,7565	0,7801	0,7798
M2	0,7681	0,7864	0,7867
RFE-26	0,7696	0,7880	0,7869
RFE-48	0,7706	0,7889	0,7893

Прирост от поиска на sel не превысил $0{,}0009$, а на rep он отсутствует или отрицателен (RFE-26: $-0{,}0011$, подгонка гиперпараметров под sel). Параметры по умолчанию близки к оптимальным, бейзлайны можно считать хорошо настроенными. Принято правило: затюненные параметры принимаются только при приросте на sel выше $2\sigma \approx 0{,}0012$; ни один набор его не проходит, значения по умолчанию сохраняются (на тесте использованы они). Правило сформулировано после просмотра rep, поэтому приводятся оба варианта. Сравнения с затюненными параметрами (rep): M2$-$M1 $+0{,}0079$ [+0,0050; +0,0105]; RFE-26$-$M1 $+0{,}0076$ [+0,0046; +0,0105]; RFE-48$-$M2 $+0{,}0020$ [+0,0003; +0,0038].

6.7. Агент и язык признаков

Результаты трёх поставщиков на 10 seed агента (M1 + принятые признаки; на каждый запуск 80 оценок, 415–479 с):

Таблица 8: Агенты, 10 seed на метод: среднее $\pm$ std по seed

Метод	принято признаков	rep	прирост к M1
random	$3{,}4 \pm 0{,}84$	$0{,}7862 \pm 0{,}0012$	$+0{,}0070 \pm 0{,}0012$
evo	$3{,}4 \pm 0{,}70$	$0{,}7860 \pm 0{,}0013$	$+0{,}0068 \pm 0{,}0013$
surrogate	$3{,}3 \pm 0{,}48$	$0{,}7862 \pm 0{,}0012$	$+0{,}0070 \pm 0{,}0012$

Разности по парам seed: evo$-$random $-0{,}0002$, surrogate$-$random $0{,}0000$ в среднем; знак меняется от seed к seed (например, evo$-$random от $-0{,}0043$ до $+0{,}0021$). **Seed влияет сильнее, чем метод; преимущество эволюционного и суррогатного поиска над случайным не обнаружено.** Принятые признаки в основном — доля скипов, средняя доля прослушивания и доля почти полных прослушиваний на длинных окнах (50–400 дней) по ключам «пара», «пользователь–исполнитель», «пользователь–альбом»; целевой показатель «скип» отсутствовал в пуле v2 и найден всеми методами. Суммарный принятый прирост на прокси завышен «проклятием победителя» (на rep прирост над M1 лишь около $0{,}007$). M1 с 3–5 добавленными признаками достигает уровня M2 (48 признаков) и немного уступает RFE-26.

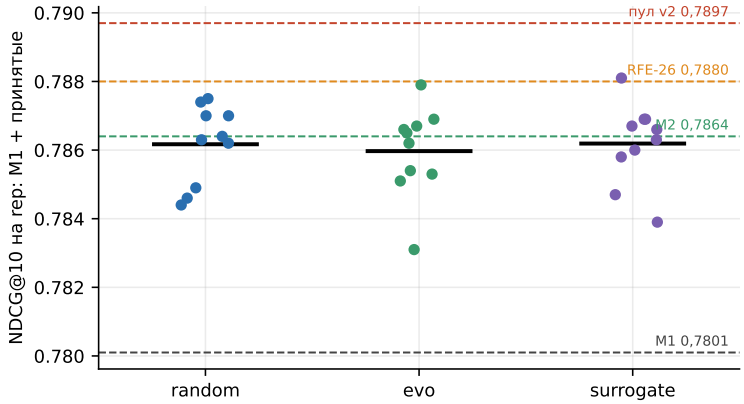


Рис. 4: NDCG@10 на rep для наборов «M1 + принятые агентом» (10 seed на метод; чёрная черта — среднее) и уровни ручных и автоматических наборов (5 seed).

6.8. Пул v3: признаки агентов поверх пула

Признаки, принятые агентами, добавлены к пулу v2. В первом запуске (26 признаков, три seed агента) RFE на пуле v3 против пула v2: $K = 48$: $-0{,}0000$ [-0,0014; +0,0014]; $K = 26$: $-0{,}0001$ [-0,0016; +0,0014]. В итоговом запуске на 10 seed (72 зарегистрированных признака) результат тот же: $K = 48$: $-0{,}0010$ [-0,0026; +0,0006]; $K = 26$: $-0{,}0012$ [-0,0026; +0,0001]. После отбора из пула v2 признаки агентов ничего измеримого не добавляют. *Объяснение — избыточность:* для 85,2% принятых признаков максимальная $|\rho|$ с признаком пула превышает 0,8, а регрессия принятого признака на признаки пула (отложенные пользователи) даёт медианный $R^2 = 0{,}951$ ($n = 71$; для 70% признаков $R^2 \geq 0{,}9$, минимум 0,476).

6.9. Графовые признаки

Вложения построены для 126 175 треков; строки покрыты на 87,3%. Качество отдельных признаков на rep: $\cos(v_i, c^+)$ (90 дней) 0,7094, $\cos(v_i, c^-)$ 0,6985, разность 0,7177 (случайный порядок 0,6950, популярность 0,7226): векторы вкуса содержат реальный сигнал. Но RFE на пуле v2 с этими признаками не превосходит RFE на пуле v2: $K = 48$ $0{,}7888 \to 0{,}7891$, $+0{,}0003$ [-0,0014; +0,0020]; $K = 26$ $0{,}7875 \to 0{,}7881$, $+0{,}0006$ [-0,0010; +0,0024]. Диагностика по типу пары: на *новых* для пользователя парах (31% строк) для $K = 48$ $+0{,}0032$ [-0,0001; +0,0067], для $K = 26$ $-0{,}0015$ [-0,0058; +0,0026]; на повторных $-0{,}0009$ [-0,0025; +0,0005] и $+0{,}0005$ [-0,0011; +0,0022]. Линейная избыточность исключена: максимальная $|\rho|$ с признаками пула 0,24–0,28; доля условной избыточности (R^2 регрессии на пул) 0,08–0,23. Остаются гипотезы (не проверены): сильные повторные прослушивания, из-за которых история пары уже несёт основной сигнал; статичность графа; малая размерность (16). Эти гипотезы частично проверены в разд. 7.4 (признаки по соседям со свежими снимками и в постановке с новыми кандидатами).

6.10. Страты и устойчивость по времени

Для сравнений RFE-26 против M1 и пула v2 против M2 разности NDCG@10 посчитаны по стратам строк rep (кластерный bootstrap по пользователям, 500 повторов; терцили по rep; абсолютные NDCG разных страт несопоставимы, важны разности).

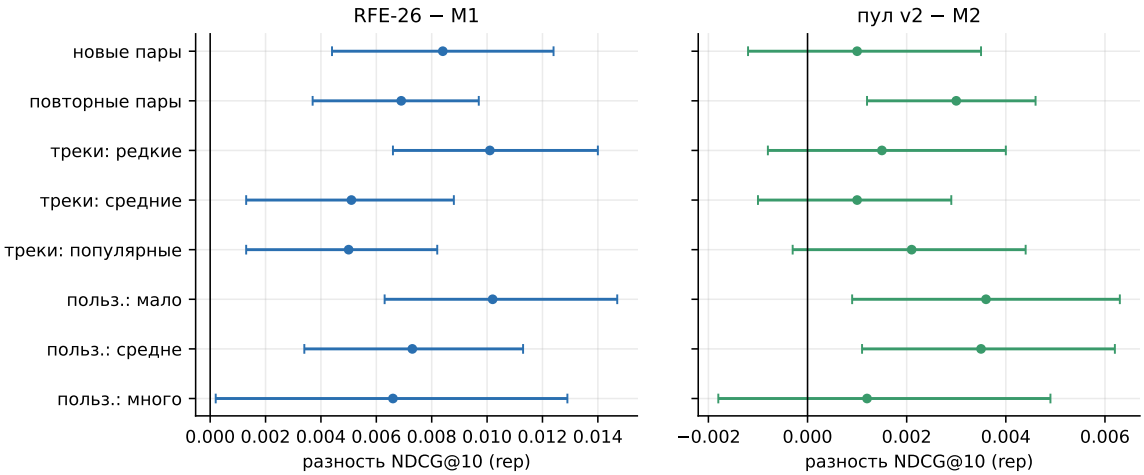


Рис. 5: Разности NDCG@10 по стратам rep (95% ДИ). Слева RFE-26 − M1, справа пул v2 − M2.

Выигрыш RFE-26 над M1 положителен во всех стратах и примерно вдвое больше там, где данных меньше: у редких треков ($+0{,}0101$ против $+0{,}0050$ у популярных) и у малоактивных пользователей ($+0{,}0102$ против $+0{,}0066$). Преимущество пула v2 над M2 значимо только на повторных парах ($+0{,}0030$) и у пользователей с низкой и средней активностью, а на новых парах и по популярности трека не отличимо от нуля. По неделям валидации (4 недели) преимущество RFE-26 над M1 положительно и значимо в каждой неделе ($+0{,}0087$, $+0{,}0074$, $+0{,}0104$, $+0{,}0068$) и не убывает; преимущество пула v2 над M2 меньше и в двух неделях из четырёх неотличимо от нуля. Срок наблюдения мал (около 25 дней).

6.11. Избыточность и устойчивость отбора

Корреляции Спирмена по 300 000 строк обучающей выборки: пул v2 (97 признаков) сильно скоррелирован — иерархическая кластеризация (средняя связь, расстояние $1 - |\rho|$) даёт 69 кластеров при $|\rho| > 0{,}95$, 46 при $0{,}9$ и 24 при $0{,}8$, то есть эффективная размерность существенно меньше числа признаков, что согласуется с малой потерей качества при сокращении до 26–48 признаков.

Устойчивость отбора проверена на 5 подвыборках по 80% пользователей (около 300 с на подвыборку): индекс Жаккара между наборами RFE на разных подвыборках $0{,}607$ для $K = 26$ (с набором RFE на полных данных $0{,}568$; в ядро, присутствующее во всех подвыборках, входят 13 признаков) и $0{,}730$ для $K = 48$ ($0{,}765$; ядро 34 признака). Набор из 26 признаков заметно менее стабилен, чем из 48: при сильной скоррелированности пула разные подвыборки выбирают разные, но взаимозаменяемые признаки; качество при этом устойчиво (разд. 6.5).

6.12. Бюджет истории

Чтобы ответить, сколько истории действительно нужно, мы ограничили память на ключ: признаки считаются только по последним B событиям группы до начала суток (число и среднее по меткам и по доле прослушивания) для ключей `user`, `ui`, `uart`, `ualb`; популярность трека (14 признаков) сохраняется неизменной.

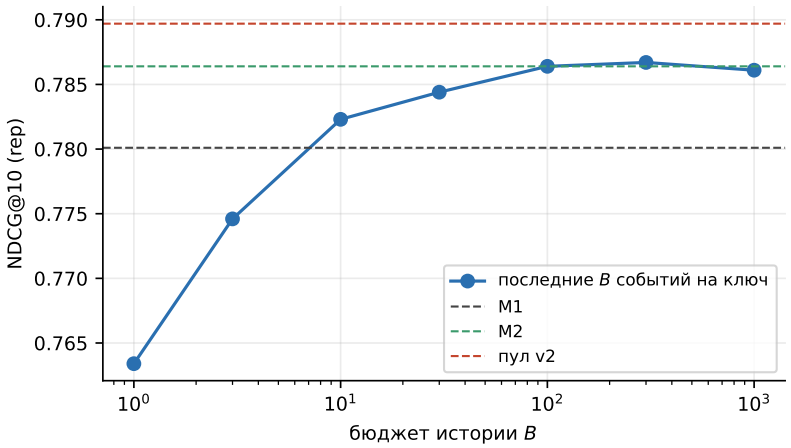


Рис. 6: NDCG@10 на rep в зависимости от бюджета истории B (один запуск, без доверительных интервалов); горизонтальные линии — наборы со временными окнами.

Качество быстро растёт до $B \approx 100$: при $B = 10$ (0,7823) оно уже выше ручного M1 (0,7801), при $B = 100$ (0,7864) совпадает с сильным ручным M2 (0,7864), а дальше выходит на плато: разности между $B = 100, 300, 1000$ ($\leq 0{,}0006$) сопоставимы с шумом запусков. Пул v2 (0,7897) остаётся выше примерно на 0,003, то есть признаки с временными окнами и давностью содержат информацию, не восстанавливаемую агрегатами по последним событиям (причина не проверялась). Вывод относится к агрегатам; для последовательных моделей он лишь указывает разумный порядок длины контекста ($K \sim 100$ событий на ключ).

6.13. Масштабируемость генератора признаков

Измерено время вычисления окон 7/30/90 дней (число и доля) для ключа «пользователь–трек» на префиксах таблицы возрастающей длины (один процесс).

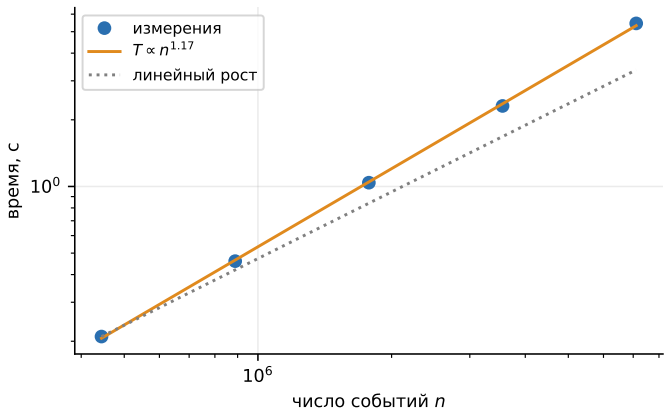


Рис. 7: Время расчёта признаков в зависимости от числа событий n (логарифмические оси): $n = 0{,}44$ млн — 0,21 с; 0,89 — 0,46; 1,78 — 1,04; 3,56 — 2,31; 7,11 млн — 5,45 с.

Показатель степени, полученный регрессией $\log T$ на $\log n$, равен 1,17 (линейный рост — 1, для $n \log n$ в этом диапазоне ожидается около 1,07; превышение естественно объясняется эффектами памяти при сортировке). Грубая экстраполяция даёт около 48 с на один ключ для всех 46,5 млн прослушиваний Yambda-50M и около $1{,}8 \cdot 10^3$ с (≈ 30 мин) для 10^9 событий в одном процессе. Оценка оптимистична: при росте n ограничением станет память ($O(n)$), поэтому в промышленных масштабах необходимы шардирование по ключу и потоковое накопление состояния (предложение 2). Экстраполяция за пределы измеренного диапазона ($\leq 7{,}1 \cdot 10^6$) носит оценочный характер.

6.14. Последовательная модель над историей (v1)

Описание модели — в разд. 5.6. Обучение заняло 74 с на GPU (2 модели $\times$ 5 эпох), стекинг (5 дообучений LightGBM) — 337 с.

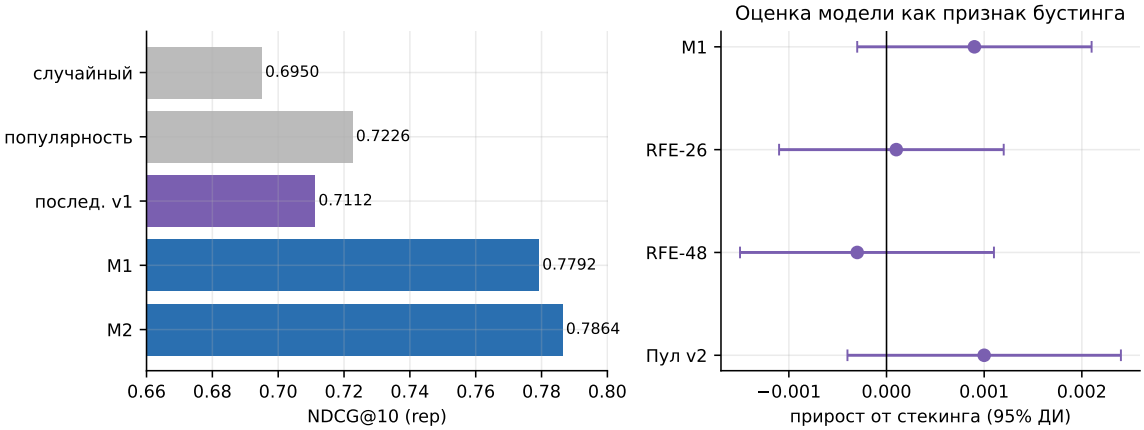


Рис. 8: Слева: NDCG@10 последовательной модели v1 на rep в сравнении с ориентирами. Справа: прирост от добавления её оценки в бустинг (95% ДИ по пользователям); все интервалы содержат ноль.

Отдельно модель даёт NDCG@10 на rep $0{,}7112$ — выше случайного порядка ($0{,}6950$), но ниже ранжирования по одной популярности ($0{,}7226$) и далеко от M1 ($0{,}7792$) и M2 ($0{,}7864$). Качество на sel почти не росло по эпохам ($0{,}676 \rightarrow 0{,}678$), хотя потери падали ($0{,}587 \rightarrow 0{,}569$; для константного предсказателя при доле положительных $0{,}639$ энтропия равна $0{,}654$). Стекинг ничего не добавляет: M1 $+0{,}0009$ [-0,0003; +0,0021]; RFE-26 $+0{,}0001$ [-0,0011; +0,0012]; RFE-48 $-0{,}0003$ [-0,0015; +0,0011]; пул v2 $+0{,}0010$ [-0,0004; +0,0024]. Гипотезы о причинах (не проверены): (a) токен содержит только 16-мерный SVD-вектор, по которому нельзя восстановить, слушал ли пользователь *именно этот* трек, а повторные прослушивания — главный сигнал (`ui_rate` даёт около 55% gain); (b) бинарная кросс-энтропия выучивает средний уровень пользователя, не влияющий на ранжирование внутри группы; (c) нет признака популярности кандидата; (d) обучение на 35 268 группах мало для трансформера. Улучшенный вариант (биты совпадения кандидата с контекстом, listwise-потери, популярность) реализован и проверен на синтетических данных, но на реальных данных не запускался и в результаты не включён.

7. Результаты: расширенная постановка с непрослушанными кандидатами

В этом разделе кандидаты — прослушанные треки и 20 негативов на группу (разд. 3.3, табл. 2). Оценка идёт по тем же группам, что и в основной постановке (с ≥ 10 прослушиваниями; на rep их 6372). Показатели на rep: случайный порядок NDCG@10 $= 0{,}4447$ (Recall@10 $0{,}1800$), популярность $0{,}6715$ ($0{,}3217$). В этом разделе выводы по rep дополняются результатами теста (разд. 8); все решения (наборы RFE, вес бленда) приняты по sel.

7.1. Сравнение наборов: rep и тест

Таблица 9: Расширенная постановка: NDCG@10 (среднее ± std по 3 seed) и Recall@10

		NDCG@10		Recall@10	
Набор	Приз.	rep	тест	rep	тест
manual18	18	$0{,}7569 \pm 0{,}0005$	$0{,}7497 \pm 0{,}0002$	0,3590	0,3525
pool90	90	$0{,}7808 \pm 0{,}0006$	$0{,}7762 \pm 0{,}0005$	0,3770	0,3717
pool90 + CF	96	$0{,}7825 \pm 0{,}0004$	$0{,}7777 \pm 0{,}0003$	0,3788	0,3730
RFE-18 из pool90	18	$0{,}7764 \pm 0{,}0003$	$0{,}7721 \pm 0{,}0008$	0,3751	0,3698
RFE-18 из pool90 + CF	18	$0{,}7753 \pm 0{,}0010$	$0{,}7708 \pm 0{,}0013$	0,3756	0,3705
только CF + популярность	36	$0{,}7370 \pm 0{,}0003$	$0{,}7293 \pm 0{,}0005$	0,3540	0,3488
бленд pool90 и CF-модели ($w = 0{,}05$)	—	0,7809	0,7766	0,3775	0,3720

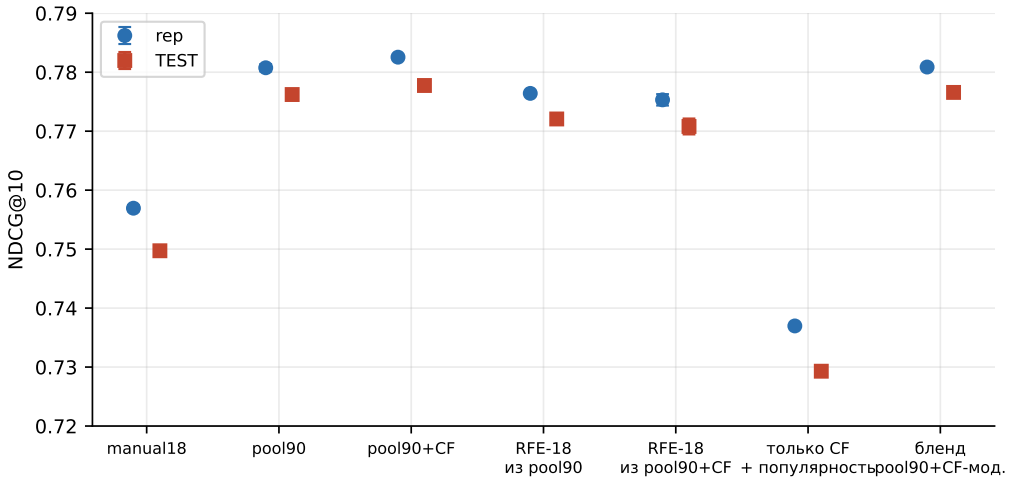


Рис. 9: Расширенная постановка: NDCG@10 наборов на rep и на тесте (среднее ± std по 3 seed).

Порядок наборов на rep и на тесте совпадает. Автоматический пул лучше ручного набора на $+0{,}0238$ [+0,0201; +0,0279] (rep) и $+0{,}0265$ [+0,0238; +0,0296] (тест); RFE-18 лучше manual18 на $+0{,}0195$ [+0,0157; +0,0236] и $+0{,}0223$ [+0,0194; +0,0254]. Это более чем вдвое больше, чем в основной постановке (M1 → пул v2: $+0{,}0119$ на тесте): включение непрослушанных кандидатов делает окна истории пары и ключей важнее, а ручной набор с окнами 1/7/30 дней не успевает охватить «длинную память». Компактный RFE-18 уступает полному пулу ($-0{,}0026$ [-0,0046; -0,0008] в первом запуске).

7.2. Кривая обучения: сколько пользователей нужно

Чтобы проверить, зависит ли выигрыш автоматизации от объёма данных, обучающая выборка наращивалась от 100 до 3000 пользователей (по 3 независимых повтора для каждого $N < 3000$, один для $N = 3000$), при фиксированных sel (499 пользователей) и rep (501 пользователь). Обучающие пользователи не пересекаются с val-пользователями; на $N = 3000$ фактически 2468 пользователей имеют строки в окне обучения (4 653 884 строки). Протокол отличается от основного (где train и val делят пользователей), поэтому абсолютные значения несколько иные.

Таблица 10: Кривая обучения: NDCG@10 на rep (среднее ± std по повторам)

N	manual18	pool90	RFE-18	pool − manual	RFE − manual	RFE − pool
100	$0{,}7507 \pm 0{,}0016$	$0{,}7705 \pm 0{,}0008$	$0{,}7674 \pm 0{,}0024$	$+0{,}0198$	$+0{,}0167$	$-0{,}0031$
200	$0{,}7535 \pm 0{,}0012$	$0{,}7747 \pm 0{,}0007$	$0{,}7705 \pm 0{,}0021$	$+0{,}0212$	$+0{,}0170$	$-0{,}0042$
400	$0{,}7544 \pm 0{,}0002$	$0{,}7767 \pm 0{,}0017$	$0{,}7729 \pm 0{,}0024$	$+0{,}0223$	$+0{,}0185$	$-0{,}0039$
800	$0{,}7553 \pm 0{,}0013$	$0{,}7784 \pm 0{,}0012$	$0{,}7755 \pm 0{,}0008$	$+0{,}0231$	$+0{,}0202$	$-0{,}0029$
1600	$0{,}7565 \pm 0{,}0000$	$0{,}7801 \pm 0{,}0016$	$0{,}7761 \pm 0{,}0008$	$+0{,}0236$	$+0{,}0196$	$-0{,}0040$
3000	0,7557	0,7802	0,7783	$+0{,}0246$	$+0{,}0226$	$-0{,}0019$

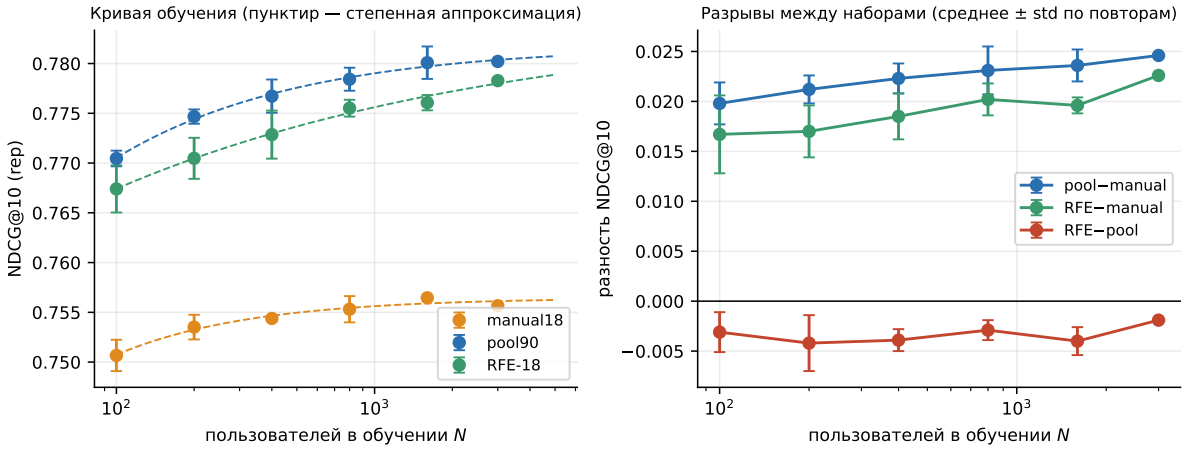


Рис. 10: Слева: кривая обучения (пунктир — аппроксимация $a - bN^{-c}$). Справа: разрывы между наборами (среднее ± std по повторам; $N = 3000$ — один запуск).

При $N = 3000$ разность pool − manual равна $+0{,}0246$ [+0,0205; +0,0292], RFE-18 − manual $+0{,}0226$ [+0,0186; +0,0274]. Выводы: (i) автоматический пул выигрывает у ручного набора уже при 100 пользователях ($+0{,}0198$), то есть автоматизация окупается и на малых данных; (ii) разрыв *растёт* с объёмом ($+0{,}0198 \to +0{,}0246$), потому что ручной набор насыщается рано, а пул продолжает улучшаться; (iii) цена компактности RFE-18 против пула стабильна ($-0{,}002 \ldots -0{,}004$) и не исчезает с ростом данных. Параметры аппроксимации $\mathrm{NDCG}(N) = a - bN^{-c}$: manual18 $a = 0{,}7565$, $c = 0{,}83$ (выход на плато ещё до $N \approx 400$); pool90 $a = 0{,}7818$, $c = 0{,}61$ (прогноз при $N = 30\,000$: 0,7814, то есть насыщение); у RFE-18 $c = 0{,}28$ и асимптота (0,7845) выше пула, что нефизично: аппроксимация по шести точкам неустойчива и для RFE не интерпретируется. Экстраполяции носят оценочный характер.

7.3. Автоматический поиск программ-признаков с нулевой калибровкой

Метод описан в разд. 5.8. Чтобы проверить, не упущен ли сигнал за пределами окон, в пул добавлены 35 примитивов (давность, возраст, интервалы) и сгенерированы выражения над базовыми признаками.

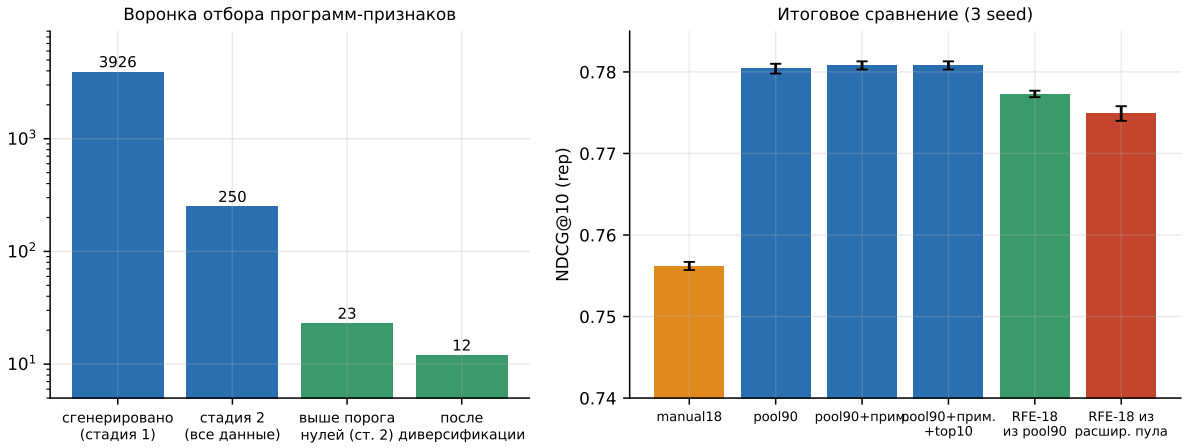


Рис. 11: Слева: воронка отбора программ-признаков (3926 реальных кандидатов $\to$ 250 на стадии 2 $\to$ 23 выше нулевого порога $\to$ 12 после диверсификации). Справа: итоговое сравнение на rep (3 seed).

Калибровка. Базовая модель (90 окон + 35 примитивов): NDCG@10 на sel $0{,}7646$. Стадия 1: 3168 оценок (400 структурных, 2468 слепых, 300 нулевых), 2,7 с на кандидата при 4 потоках; медианный прирост отрицателен ($-0{,}0004$: маленькая модель на 30% данных в среднем добавляет шум — смещение оценщика), порог (99-й процентиль нулей) $+0{,}00042$. Выше порога оказалось **17 из 2868** реальных кандидатов; ожидаемое число ложных принятий — около 29 (грубая оценка 1%) или до 38 (предложение 4: $2868 \cdot 4/301$). То есть число прошедших порог *не превышает* число, ожидаемое от шума. Раунд 2 (1058 кандидатов глубины 2) — медианный прирост $-0{,}0003$. Стадия 2 (250 лучших и 60 нулей на всех данных, около 27 с на оценку): порог $+0{,}00039$, прошли 23 из 250, лучший прирост $+0{,}00095$.

Финальные модели. В абляции по категориям присутствовали только «слепые» кандидаты и глубина 2: структурные категории (тренд, иерархия, давность/интервалы, burst) не дали кандидатов, прошедших порог стадии 2.

Таблица 11: Поиск программ: наборы на sel и rep (3 seed), разности с 95% ДИ на rep

Набор	Приз.	sel	rep
manual18	18	0,7344	$0{,}7562 \pm 0{,}0005$
pool90	90	0,7650	$0{,}7804 \pm 0{,}0006$
pool90 + примитивы	125	0,7658	$0{,}7808 \pm 0{,}0005$
pool90 + примитивы + 10 программ (выбор N по sel)	135	0,7663	$0{,}7808 \pm 0{,}0005$
RFE-18 из pool90	18	0,7627	$0{,}7773 \pm 0{,}0004$
RFE-18 из расширенного пула	18	0,7610	$0{,}7749 \pm 0{,}0009$

Таблица 12: Поиск программ: разности (rep)

Сравнение	Разность NDCG@10 (95% ДИ)
pool90 − manual18	$+0{,}0238$ [+0,0201; +0,0279]
pool90 + примитивы − pool90	$+0{,}0004$ [-0,0007; +0,0015]
+ 10 программ − pool90 + примитивы	$-0{,}0003$ [-0,0014; +0,0008]
+ 10 программ − pool90	$+0{,}0001$ [-0,0011; +0,0013]
RFE-18 (расш.) − RFE-18 (pool90)	$-0{,}0018$ [-0,0033; -0,0003]
7 «слепых» − pool90 + примитивы	$+0{,}0000$ [-0,0010; +0,0011]
10 «глубина 2» − pool90 + примитивы	$-0{,}0008$ [-0,0018; +0,0002]

Вывод. Новые примитивы и $\sim$4000 программ не дают измеримого прироста над пулом из 90 окон; расширение пула лишь ухудшает компактный RFE-отбор ($-0{,}0018$, значимо). Нулевая калибровка предотвратила ложный вывод: на стадии 2 прошли 23 кандидата с приростом до $+0{,}00095$ на остатках, но в полной модели их вклад не отличим от нуля. Гипотеза о том, что «давность относительно привычного интервала повторов» добавит сигнал, не подтвердилась. Всё вместе — ещё одно свидетельство насыщения агрегатов истории (разд. 10). Время всего запуска 6,94 ч (стадия 1: 2,5 ч; раунд 2: 0,8 ч; стадия 2: 2,3 ч; финал: 1,4 ч).

7.4. Коллаборативные признаки

Признаки описаны в разд. 5.7: 13 недельных снимков, граф из 9238 пользователей и 29 439 278 дослушиваний, 3 344 494 строки запросов (rep/sel/train), расчёт 7–9 минут. Непустые значения `cf_u50` на rep — 98,3%; доля позитивов, новых для пользователя, — 29,2%.

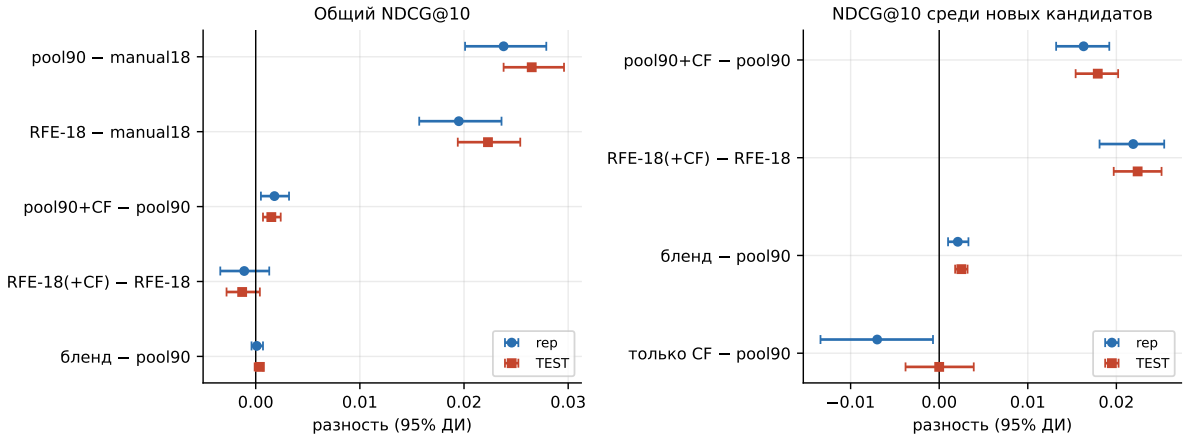


Рис. 12: Расширенная постановка: разности наборов на rep и на тесте (95% ДИ). Слева общий NDCG@10, справа NDCG@10 среди новых для пользователя кандидатов.

Таблица 13: Расширенная постановка: качество по типу пары (rep / тест)

Набор	Recall новых	Recall повторных	NDCG@10 среди новых
manual18	0,115 / 0,119	0,454 / 0,443	0,639 / 0,635
pool90	0,110 / 0,110	0,488 / 0,481	0,753 / 0,745
pool90 + CF	0,117 / 0,118	0,485 / 0,477	0,769 / 0,762
RFE-18 из pool90	0,107 / 0,109	0,487 / 0,480	0,743 / 0,735
RFE-18 из pool90 + CF	0,112 / 0,115	0,484 / 0,476	0,764 / 0,758
только CF + популярность	0,199 / 0,211	0,408 / 0,396	0,746 / 0,745
бленд	0,111 / 0,111	0,488 / 0,481	0,755 / 0,747

Эффект. pool90+CF − pool90: общий NDCG@10 $+0{,}0018$ [+0,0005; +0,0032] (rep) и $+0{,}0015$ [+0,0007; +0,0024] (тест); среди новых кандидатов $+0{,}0163$ [+0,0132; +0,0192] и $+0{,}0179$ [+0,0154; +0,0202]. Общий эффект мал, потому что новые пары составляют около 29% позитивов, а в топ-10 доминируют повторные треки; на новых кандидатах эффект на порядок больше. Recall новых позитивов растёт на $+0{,}0061$ [+0,0030; +0,0090] при потере Recall повторных $-0{,}0030$ [-0,0050; -0,0013] (rep): CF перераспределяет места в топ-10 в пользу новых треков.

Компактный отбор. RFE-18 из пула с CF выбрал три CF-признака (`cf_u200`, `cf_mf_dot`, `cf_u50cnt`); NDCG среди новых вырос на $+0{,}0219$ [+0,0181; +0,0254] (rep) и $+0{,}0224$ [+0,0197; +0,0251] (тест),

но общий NDCG не улучшился ($-0{,}0011$ [-0,0034; +0,0013] и $-0{,}0013$ [-0,0028; +0,0004]): при бюджете 18 признаков CF вытесняет признаки истории.

Модель только на CF. Показывает самый высокий Recall новых позитивов ($0{,}199$ / $0{,}211$), но проигрывает по общему NDCG ($-0{,}0438$ / $-0{,}0469$) из-за потери повторных треков. Ее NDCG среди новых на тесте совпадает с pool90 ($+0{,}0000$ [-0,0038; +0,0039]), то есть сигнал соседей по вкусу сопоставим с сигналом истории пользователя на новых треках. **Бленд** (поздняя фузия оценок, вес по sel $w = 0{,}05$) почти ничего не даёт ($+0{,}0004$ [-0,0001; +0,0007] на тесте) и значимо хуже, чем встраивание CF-признаков в одну модель ($-0{,}0012$ общего NDCG на тесте): взаимодействие CF-признаков с признаками истории внутри деревьев важно.

Таблица 14: Отключение CF-признаков по одному от pool90+CF (rep, один seed): разность к полному набору (95% ДИ)

Без признака	Δ NDCG@10	Δ Recall новых
`cf_u50`	$-0{,}0009$ [-0,0020; +0,0002]	$+0{,}0008$ [-0,0011; +0,0027]
`cf_u50cnt`	$-0{,}0011$ [-0,0023; +0,0000]	$-0{,}0000$ [-0,0016; +0,0015]
`cf_u200`	$-0{,}0007$ [-0,0018; +0,0004]	$+0{,}0018$ [-0,0001; +0,0037]
`cf_mf_dot`	$-0{,}0017$ [-0,0029; -0,0003]	$-0{,}0026$ [-0,0046; -0,0005]
`cf_mf_cos`	$-0{,}0006$ [-0,0016; +0,0006]	$-0{,}0003$ [-0,0019; +0,0014]
`cf_deg`	$-0{,}0021$ [-0,0033; -0,0010]	$-0{,}0007$ [-0,0025; +0,0010]

Наиболее важны популярность по графу (`cf_deg`) и факторизационная оценка (`cf_mf_dot`); признаки по ближайшим соседям по отдельности взаимозаменяемы.

Масштаб коллаборативного корпуса. Соседи искались среди 1371 (только пользователи выборки), 3000, 6000 и всех 9238 пользователей.

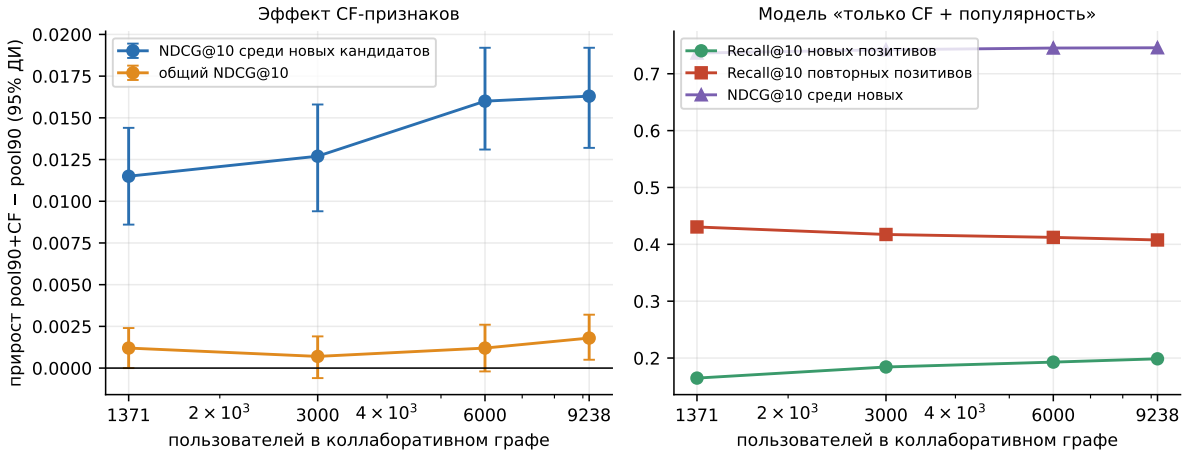


Рис. 13: Слева: эффект CF-признаков (pool90+CF − pool90, 95% ДИ) в зависимости от числа пользователей в графе. Справа: модель «только CF + популярность».

Эффект на новых кандидатах растёт монотонно: $+0{,}0115$ [+0,0086; +0,0144] $\to$ $+0{,}0127$ [+0,0094; +0,0158] $\to$ $+0{,}0160$ [+0,0131; +0,0192] $\to$ $+0{,}0163$ [+0,0132; +0,0192] (1371 / 3000 / 6000 / 9238 пользователей); общий NDCG — $+0{,}0012$, $+0{,}0007$, $+0{,}0012$, $+0{,}0018$ (интервалы частично включают ноль). У модели только на CF растёт Recall новых позитивов ($0{,}165 \to 0{,}184 \to 0{,}193 \to 0{,}199$) и NDCG среди новых ($0{,}736 \to 0{,}742 \to 0{,}745 \to 0{,}746$), при этом Recall повторных падает ($0{,}431 \to 0{,}408$). Рост, замедляющийся на последних шагах, согласуется с насыщающейся зависимостью; на 9238

пользователях в графе экстраполяцию делать нельзя. Практический вывод: польза коллаборативного сигнала зависит от размера графа, а промышленный граф на порядки больше нашего.

8. Финальная оценка на тестовой выборке

Процедура. Наборы признаков заморожены до запуска (файлы `finalists_FROZEN.json`); для основной постановки использованы наборы M1, M2, RFE-26, RFE-48, пул v2, отобранные по sel (RFE) до просмотра теста; гиперпараметры по умолчанию; обучение на train-окне, ранняя остановка по sel; оценка на всех тестовых группах (период $\approx 22{,}7$ дня, 711 011 строк), 5 seed на набор. Результаты теста не использовались для выбора чего-либо; повторный запуск блокируется (`TEST_LOCK.json`). Для расширенной постановки — аналогично (3 seed, тест 15 901 групп; наборы RFE выбраны по sel).

Таблица 15: Основная постановка: NDCG@10 на тесте и на rep (5 seed, среднее $\pm$ std)

Набор	Приз.	Тест	rep (валидация)
случайный порядок	0	0,6926	0,6950
популярность (`gitem_rate_30d`)	0	0,7138	0,7226
M1 (ручной)	26	$0{,}7721 \pm 0{,}0005$	$0{,}7801 \pm 0{,}0006$
M2 (сильный ручной)	48	$0{,}7812 \pm 0{,}0002$	$0{,}7864 \pm 0{,}0003$
RFE-26	26	$0{,}7824 \pm 0{,}0002$	$0{,}7880 \pm 0{,}0003$
RFE-48	48	$0{,}7830 \pm 0{,}0003$	$0{,}7889 \pm 0{,}0004$
Пул v2	97	$0{,}7839 \pm 0{,}0004$	$0{,}7897 \pm 0{,}0004$

Таблица 16: Основная постановка: разности на тесте (95% ДИ, кластерный bootstrap по пользователям) и на rep

Сравнение	Тест	rep (один запуск)
M2 − M1	$+0{,}0091$ [+0,0073; +0,0110]	$+0{,}0073$ [+0,0047; +0,0097]
RFE-26 − M1	$+0{,}0104$ [+0,0083; +0,0124]	$+0{,}0084$ [+0,0055; +0,0111]
RFE-26 − M2	$+0{,}0013$ [-0,0001; +0,0025]	(по 5 seed: $+0{,}0016$)
RFE-48 − M2	$+0{,}0019$ [+0,0007; +0,0030]	$+0{,}0028$ [+0,0010; +0,0046]
Пул v2 − M2	$+0{,}0028$ [+0,0017; +0,0038]	$+0{,}0030$ [+0,0014; +0,0048]
Пул v2 − RFE-48	$+0{,}0009$ [+0,0002; +0,0017]	—
Пул v2 − M1	$+0{,}0119$ [+0,0098; +0,0141]	—

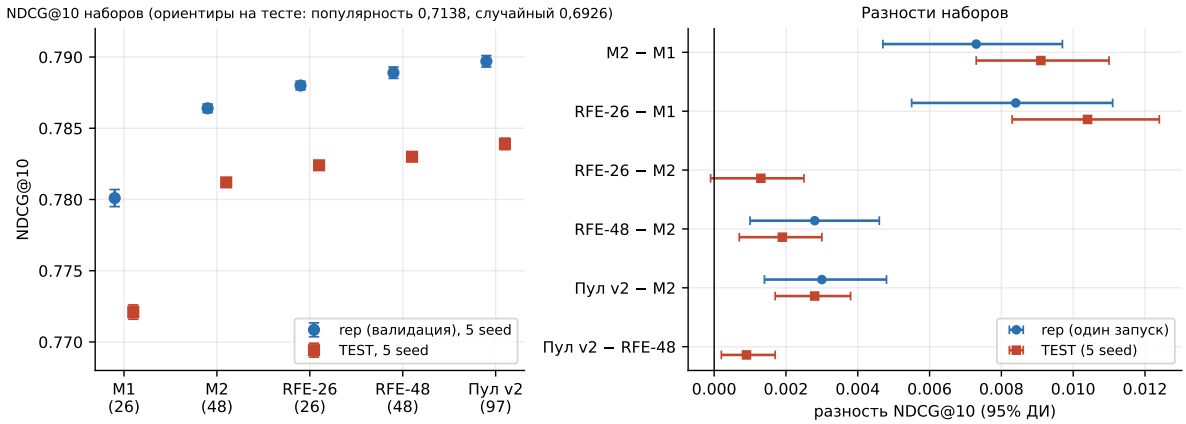


Рис. 14: Основная постановка. Слева: NDCG@10 наборов на rep и на тесте. Справа: разности наборов (95% ДИ); для RFE-26 − M2 и пула v2 − RFE-48 на rep доверительные интервалы не вычислялись.

Что подтвердилось и что нет.

- **Подтвердилось:** все наборы лучше популярности и случайного порядка; порядок M1 < M2 < RFE-26 < RFE-48 < пул v2 сохранился; автоматический отбор на 48 признаков и полный пул значимо лучше сильного ручного набора M2 ($+0{,}0019$ и $+0{,}0028$); все наборы существенно лучше M1.
- **RFE-26 против M2:** точечная оценка RFE-26 выше M2 (+0,0013), но интервал включает ноль. Поэтому по этим данным нельзя доказать ни превосходство, ни статистическую не меньшую эффективность RFE-26; для вывода о не меньшей эффективности заранее требуется задать допустимую границу.
- **Систематический сдвиг:** абсолютные значения на тесте на 0,005–0,008 ниже, чем на rep (другой период, тест не участвовал в отборе); разности между наборами сохраняются (в пределах интервалов).

В расширенной постановке на тесте результаты совпали с rep (табл. 9, рис. 12): pool90 − manual18 $+0{,}0265$ [+0,0238; +0,0296], pool90+CF − pool90 $+0{,}0015$ [+0,0007; +0,0024], RFE-18 из пула с CF − RFE-18 из pool90 $-0{,}0013$ [-0,0028; +0,0004]; на новых кандидатах pool90+CF − pool90 $+0{,}0179$ [+0,0154; +0,0202].

9. Вычислительные затраты

Затраты приведены для 4 потоков CPU (Kaggle); время обучения — на один seed.

Таблица 17: Вычислительные затраты этапов

Этап	Время
Расчёт окон (ключ `ui`, 7,1 млн событий)	5,45 с, $T \propto n^{1,17}$ (разд. 6.13)
Обучение, основная постановка (train-окно, 60 дн.)	M1 ≈ 41 с; M2 ≈ 59 с; RFE-26 ≈ 44 с; RFE-48 ≈ 66 с; пул v2 ≈ 99 с
Обучение, расширенная (2,3 млн строк)	manual18 42 с; pool90 151 с; pool90+CF 175 с; CF-модель 118 с; RFE-18 ≈ 75 с
Отбор: A1 / RFE 97→48→26 / жадный	одно обучение / 424 с (9 обучений) / 26,7 мин
Отбор RFE-18, расширенная постановка	из pool90 ≈ 16 мин; из pool90+CF ≈ 20 мин
Агент (80 оценок на запуск)	415–479 с на запуск; 30 запусков вместе с RFE на пуле v3 (970 с) — 4,3 ч
Поиск программ (~ 4000 кандидатов, 2 стадии)	6,94 ч, из них стадия 1 — 2,5 ч, стадия 2 — 2,3 ч
CF-признаки (13 снимков, 3,3–4,4 млн строк)	420–537 с (полный граф); 181 с (1371), 299 с (3000), 425 с (6000)
Кривая обучения ($N = 100 \dots 3000$, 3 набора)	2,67 ч суммарно; при $N = 3000$: manual18 95 с, pool90 267 с, RFE-18 (отбор + обучение) около 36 мин
Последовательная модель v1	обучение 74 с (GPU), стекинг 337 с

Главное практическое наблюдение: стоимость RFE-отбора (десятки минут) несопоставимо мала по сравнению с ручной разработкой набора признаков и окупается на любом объёме данных (разд. 7.2); дорогим оказался только неудачный поиск программ-признаков (часы вычислений без выигрыша).

10. Обсуждение

10.1. Ответ на вопрос задания

Можно ли автоматизировать построение признаков или заменить их обучаемыми представлениями без потери качества? Наши результаты дают дифференцированный ответ.

1. **Автоматизация отбора и выбора масштаба — да, и с выигрышем.** Широкий пул окон и отбор из него (RFE) превосходят ручной выбор окон при том же числе признаков (на тесте: RFE-48 − M2 $+0{,}0019$, пул v2 − M2 $+0{,}0028$, интервалы строго положительны) и при вдвое меньшем числе признаков не уступают (RFE-26 против M2: $+0{,}0013$, ноль в интервале). Причина: оптимальный масштаб окна зависит от агрегата (разд. 6.2), а ручной выбор единой сетки неизбежно теряет качество.
2. **Автоматическая *генерация новых* признаков из истории пользователя — нет.** Три поставщика агентов статистически неразличимы (10 seed), а поиск ~ 4000 программ с калибровкой по нулевому распределению не находит ничего выше шума. Это насыщение агрегатов истории: признаки агентов на 70–85% линейно и условно восстанавливаются из пула (медианный $R^2 = 0{,}95$).
3. **Информация другой природы помогает.** Сигнал других пользователей (коллаборативные признаки) улучшает ранжирование новых для пользователя треков ($+0{,}018$ NDCG среди новых на тесте), эффект растёт с размером графа; общий выигрыш мал из-за доминирования повторных прослушиваний в топе.
4. **Обучаемые представления над историей (трансформер v1) не заменяют ручные/автоматические агрегаты.** 0,7112 против 0,7792; в стекинге нет прироста. Причины v1, вероятно, в отсутствии идентичности трека и в функции потерь (гипотезы, не проверены).

10.2. Почему агрегаты насыщены, а постановка важна

История пользователя содержит конечное количество информации о «повторном потреблении»: после того как `ui_rate` и `ui_cnt` посчитаны на нескольких масштабах, давность, интервалы, тренды и композиции признаков добавляют менее 10^{-3} NDCG (бюджет истории: последних 100 событий на ключ достаточно для уровня M2; программы-выражения ничего не добавляют). Кардинально другая картина — на кандидатах, которых пользователь не слушал: там история пары пуста, а полезны популярность и сигнал соседей. Разрыв между ручным и автоматическим набором втрое больше в постановке с негативами ($+0{,}0265$ против $+0{,}0119$ на тесте), то есть постановка с непрослушанными кандидатами сильнее различает методы и ближе к реальной выдаче.

10.3. Масштаб данных

Кривая обучения (разд. 7.2) показывает две вещи: (a) автоматизация окупается уже при 100 пользователях; (b) ручной набор насыщается при ~ 400 пользователях, а пул продолжает улучшаться, поэтому разрыв растёт с данными. Для промышленных объёмов можно ожидать, что ручные признаки перестанут масштабироваться, но выигрыш полного пула также выходит на насыщение (прогноз $+0{,}0004$ при росте в 10 раз), и дальнейшие улучшения придётся искать в информации иной природы (CF, последовательности, контент).

10.4. Статистическая осторожность

Абсолютные приросты скромны ($0{,}002$–$0{,}008$ NDCG@10 при приросте над случайным порядком около $0{,}09$), но воспроизводимы по seed и подкреплены интервалами по пользователям. Три урока методологического характера: (1) разность ещё не значимая на rep (RFE-26 против M2) не подтвердилась на тесте, хотя по направлению сохранилась; (2) «победители» перебора кандидатов (агенты: $+0{,}013$ на прокси, $+0{,}007$ на rep; поиск программ: $+0{,}00095$ на стадии 2, 0 в полной модели) — следствие отбора по шумной метрике; нулевая калибровка превращает этот риск в количественную оценку; (3) одно и то же решение по sel нужно проверять на отложенных пользователях и периоде.

11. Ограничения

- **Нет данных о показах.** В основной постановке кандидаты — только прослушанные треки, поэтому NDCG измеряет ранжирование внутри прослушанного. В расширенной постановке негативы синтетические (непрослушанные, а не «показанные и отвергнутые»); способ выбора негативов (20 на группу, смесь равномерных и популярных) не варьировался.
- **Одна подвыборка и один датасет.** 1500 из 10 000 пользователей, одно временное разбиение, период около 300 дней. Частичная проверка обобщения — кривая обучения на других пользователях (разд. 7.2); второй датасет (KION) не использовался. Доверительные интервалы малы лишь по пользователям выбранной подвыборки и не учитывают отбор признаков по sel.
- **Многократное использование rep.** Решения по методам принимались по sel, но rep использовалась многократно для сравнений, а правило для гиперпараметров сформулировано после просмотра rep. Оценки rep слегка оптимистичны; финальный тест от этого свободен (один запуск), но наборы RFE и бленд-вес выбраны по sel.
- **Метка и данные.** Метка зависит от порога 50%; соответствие трека альбому неоднозначно (у 997 861 трека несколько альбомов, у 1400 несколько исполнителей), использована первая запись, что ухудшает признаки `ualb`/`uart`. Метка становится известна по окончании прослушивания: для событий на границе суток возможен малый эффект.
- **Коллаборативные признаки** — простейшие (косинусные соседи, случайный SVD, бинарная матрица): без временного затухания, без лайков, снимки раз в неделю (устаревание до 7

дней), граф из 9238 пользователей. Эффект на масштабе промышленных графов не измерялся; экстраполяция по размеру графа не делалась.

- **Кривая обучения:** точка $N = 3000$ — один запуск (фактически 2468 пользователей); аппроксимация степенным законом по шести точкам оценочная; протокол (непересекающиеся обучающие и val-пользователи) отличается от основного.
- **Последовательная модель** оценена только в первой версии (разд. 6.14); улучшенная версия реализована, но не запускалась. **LLM-поставщик** предложений реализован, но не оценивался.
- **Не включено в отчёт:** признаки явной обратной связи (лайки/дизлайки) и ядра затухания реализованы в коде, но результаты их сравнения не сведены; графовые признаки, признаки агентов и последовательная модель оценены только на валидации (не на тесте).
- **Эксперимент по бюджету истории** выполнен в одном запуске без интервалов; замер масштабируемости — на одной машине и в одном процессе, экстраполяция за измеренный диапазон оценочная. Аудио-эмбеддинги (около 13,8 ГБ) не использовались из-за размера.
- **Метрики:** LogLoss и ROC-AUC (упомянутые в условии) в итоговых экспериментах не вычислялись; исторические значения AUC приведены только для протокольного артефакта (разд. 6.1).

12. Заключение и перспективы

12.1. Заключение

Построен воспроизводимый конвейер без утечек (снимок на начало суток, ранжирование внутри групп, sel/rep/test, кластерный bootstrap, замороженные наборы и одноразовый тест). На нём показано: скользящие окна дают ложные приросты; оптимальный масштаб окна зависит от агрегата; автоматический отбор из широкого пула не хуже, а при том же числе признаков лучше ручного выбора, и выигрыш растёт при постановке, близкой к реальной (негативы) и с объёмом данных; новые признаки из истории (агенты, программы, примитивы) не дают прироста — агрегаты насыщены; коллаборативная информация других пользователей даёт заметный выигрыш на новых для пользователя треках и масштабируется с размером графа; небольшой трансформер над историей не конкурирует. Три направления из условия (автоматическая генерация, графовые модели, модели над историей) исследованы; ни одно не превзошло бустинг на автоматически отобранных агрегатах истории, но коллаборативное направление указывает, где искать дальнейший прирост.

12.2. Перспективы и невыполненные эксперименты

- **Последовательные модели.** Запуск улучшенной версии: биты совпадения кандидата с контекстом (трек/исполнитель/альбом), listwise-потери, популярность кандидата, длина контекста $K \sim 100$ (по разд. 6.12), стекинг с кросс-подгонкой; обучаемые эмбеддинги идентификаторов треков [7, 6].
- **LLM-поставщик программ** (реализован) в сравнении с суррогатным и слепым поиском на языке выражений.
- **Коллаборативные сигналы:** факторизации с временным затуханием (ALS), лайки как положительный сигнал, суточные снимки, граф размера промышленных данных (Yambda-500M/5B); измерение, как растёт эффект.
- **Постановка:** показы вместо синтетических негативов; двухэтапная схема (генерация кандидатов + ранжирование); цель на лайки как в официальном протоколе Yambda.
- **Обобщение:** повтор на другом датасете (KION) и на нескольких временных разбиениях; LogLoss и ROC-AUC; тест на утечку возмущением будущих меток как обязательный шаг конвейера.

13. Воспроизводимость

Основные эксперименты выполнены в Google Colab и Kaggle; согласно сохранённым журналам, базовые результаты (случайный порядок, популярность, M1, абляции, кривая окон и пул v1) совпали до четвёртого знака. Поздние эксперименты (разд. 7–8) выполнены на Kaggle с 4 потоками CPU; GPU использовался для последовательной модели v1. В приложенном архиве `t-lab.zip` находятся ноутбуки и журналы результатов. Большие исходные данные, промежуточные parquet-кэши и некоторые автоматически создаваемые файлы состояния в архив не включены; ноутбуки очищены от outputs. Поэтому для полного повторного прогона нужны доступ к исходному датасету, среда с зависимостями из `requirements.txt` и повторное выполнение ноутбуков. Сохранённые журналы позволяют сверить ключевые численные результаты без повторного запуска всех длительных экспериментов.

Таблица 18: Состав приложенного архива `t-lab.zip` и назначение ноутбуков

Файл	Назначение
`01_baseline_and_feature_pool.ipynb`	Базовая постановка, временные окна, ручные признаки и расширенный пул
`02_feature_search_and_graph.ipynb`	Отбор признаков, агентные эксперименты и графовые признаки
`03_extended_experiments.ipynb`	Последовательная модель v1 и дополнительные эксперименты основной постановки
`04_negative_candidates.ipynb`	Расширенная постановка с негативными кандидатами и коллаборативными признаками
`05_autofe_search.ipynb`	Поиск программ-признаков с калибровкой по нулевым кандидатам
`06_final_evaluation.ipynb`	Финальная оценка замороженных наборов на тестовой выборке
`results/*.txt`	Журналы длительных запусков и сводка ключевых результатов
`README.md`, `requirements.txt`	Описание проекта, порядка работы и зависимостей

Seed и состояние экспериментов. В экспериментах зафиксированы seed: подвыборка пользователей — 42; разбиение validation на sel/rep — 123; обучение основной постановки и теста — 0–4; расширенной постановки — 0–2; случайный SVD для CF — `random_state=0`. Для экспериментов с негативами использовались отдельные seed, описанные в коде и журналах. Финальные наборы и блокировка повторного тестирования упоминаются в исходном протоколе; сами файлы состояния и кэши не входят в архив, поэтому их наличие в архиве не предполагается.

Окружение и доступ к коду. В архив приложены ноутбуки, `README.md`, `requirements.txt` и журналы. Публичная ссылка на репозиторий не указана: вместо неё в исходной версии стоял шаблонный URL, который нельзя использовать для проверки. Для независимого запуска следует использовать приложенный архив и предварительно получить исходный датасет Yambda-50M.

Использование ИИ-инструментов

При подготовке работы использовались ИИ-инструменты, включая ChatGPT (OpenAI) и Claude (Anthropic), для обсуждения экспериментального плана, разработки и отладки кода, а также подготовки черновика текста. ИИ-инструменты не являются источником экспериментальных результатов: численные значения в отчёте сверялись с сохранёнными журналами запусков. Автор отвечает за постановку экспериментов, интерпретацию результатов и окончательный текст. Существование публикаций и основные библиографические сведения сверены по страницам издателей, конференций и arXiv. Ссылки используются для обоснования соответствующих методов и постановок; автор

отвечает за то, чтобы формулировки в отчёте не выходили за пределы того, что подтверждают цитируемые источники.

Список литературы

[1] J. M. Kanter, K. Veeramachaneni. Deep feature synthesis: Towards automating data science endeavors. *IEEE Int. Conf. on Data Science and Advanced Analytics (DSAA)*, 2015.

[2] T. Zhang et al. OpenFE: Automated feature generation with expert-level performance. *ICML* (PMLR 202), 2023; arXiv:2211.12507.

[3] N. Hollmann, S. Müller, F. Hutter. Large language models for automated data science: Introducing CAAFE for context-aware automated feature engineering. *NeurIPS*, 2023; arXiv:2305.03403.

[4] N. Abhyankar, P. Shojaee, C. K. Reddy. LLM-FE: Automated feature engineering for tabular data with LLMs as evolutionary optimizers. *Transactions on Machine Learning Research*, 2026; arXiv:2503.14434.

[5] M. Fey et al. Position: Relational deep learning — graph representation learning on relational databases. *ICML* (PMLR 235), 2024; arXiv:2312.04615.

[6] J. Zhai et al. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *ICML* (PMLR 235), 2024; arXiv:2402.17152.

[7] W.-C. Kang, J. McAuley. Self-attentive sequential recommendation. *IEEE ICDM*, 2018; arXiv:1808.09781.

[8] A. Vaswani et al. Attention is all you need. *NeurIPS*, 2017.

[9] P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, J. Riedl. GroupLens: An open architecture for collaborative filtering of netnews. *ACM CSCW*, 1994.

[10] Y. Koren, R. Bell, C. Volinsky. Matrix factorization techniques for recommender systems. *IEEE Computer* 42(8), 2009, 30–37.

[11] N. Halko, P.-G. Martinsson, J. A. Tropp. Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review* 53(2), 2011, 217–288.

[12] L. Grinsztajn, E. Oyallon, G. Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? *NeurIPS (Datasets and Benchmarks)*, 2022; arXiv:2207.08815.

[13] Y. Ji, A. Sun, J. Zhang, C. Li. A critical study on data leakage in recommender system offline evaluation. *ACM Transactions on Information Systems*; arXiv:2010.11060.

[14] A. Ploshkin et al. Yambda-5B — a large-scale multi-modal dataset for ranking and retrieval. arXiv:2505.22238, 2025.

[15] G. Ke et al. LightGBM: A highly efficient gradient boosting decision tree. *NeurIPS*, 2017.

[16] C. J. C. Burges. From RankNet to LambdaRank to LambdaMART: An overview. Microsoft Research Technical Report MSR-TR-2010-82, 2010.

[17] K. Järvelin, J. Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems* 20(4), 2002, 422–446.

[18] T. Akiba et al. Optuna: A next-generation hyperparameter optimization framework. *KDD*, 2019.

[19] C. A. Field, A. H. Welsh. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B* 69(3), 2007, 369–390.

[20] B. Efron. Large-scale simultaneous hypothesis testing: The choice of a null hypothesis. *Journal of the American Statistical Association* 99(465), 2004, 96–104.

[21] Y. Benjamini, Y. Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B* 57(1), 1995, 289–300.

[22] J. Kaplan et al. Scaling laws for neural language models. arXiv:2001.08361, 2020.

A. Дополнительные таблицы

A.1. Качество одной фичи по окнам

Таблица 19: NDCG@10 одной фичи (`ui`) по окнам (val)

w	1	2	3	5	7	10	14	21	30	45	60	90	120	180	400
rate	.7039	.7089	.7125	.7174	.7199	.7232	.7261	.7295	.7314	.7331	.7344	.7362	.7368	.7396	.7396
cnt	.7028	.7094	.7123	.7165	.7192	.7210	.7235	.7268	.7288	.7294	.7280	.7264	.7247	.7241	.7221

A.2. Страты и недели: полные таблицы (rep)

Таблица 20: Разности NDCG@10 по стратам rep: Δ и 95% ДИ

Страта	доля строк	RFE-26 − M1	пул v2 − M2
пары новые	0,307	+0,0084 [+0,0044; +0,0124]	+0,0010 [-0,0012; +0,0035]
пары повторные	0,693	+0,0069 [+0,0037; +0,0097]	+0,0030 [+0,0012; +0,0046]
популярность трека: низкая	0,334	+0,0101 [+0,0066; +0,0140]	+0,0015 [-0,0008; +0,0040]
популярность трека: средняя	0,333	+0,0051 [+0,0013; +0,0088]	+0,0010 [-0,0010; +0,0029]
популярность трека: высокая	0,333	+0,0050 [+0,0013; +0,0082]	+0,0021 [-0,0003; +0,0044]
активность пользователя: низкая	0,333	+0,0102 [+0,0063; +0,0147]	+0,0036 [+0,0009; +0,0063]
активность пользователя: средняя	0,334	+0,0073 [+0,0034; +0,0113]	+0,0035 [+0,0011; +0,0062]
активность пользователя: высокая	0,333	+0,0066 [+0,0002; +0,0129]	+0,0012 [-0,0018; +0,0049]

Таблица 21: Устойчивость по времени: разности по неделям валидации (rep)

Неделя	доля строк	RFE-26 − M1	пул v2 − M2
36	0,205	+0,0087 [+0,0032; +0,0134]	+0,0038 [+0,0004; +0,0075]
37	0,284	+0,0074 [+0,0027; +0,0123]	+0,0022 [-0,0007; +0,0055]
38	0,290	+0,0104 [+0,0062; +0,0156]	+0,0051 [+0,0020; +0,0084]
39	0,222	+0,0068 [+0,0010; +0,0123]	+0,0006 [-0,0033; +0,0041]